Universidade de São Paulo Escola Superior de Agricultura "Luiz de Queiroz"

Deep learning para identificação de déficit hídrico em plantas com	base	em
imagens térmicas		

Leonardo Leite de Melo

Tese apresentada para obtenção do título de Doutor em Ciências. Área de concentração: Engenharia de Sistemas Agrícolas

Leonardo Leite de Melo Bacharel em Ciência da Computação

Deep learning para identificação de déficit hídrico em plantas com base em imagens térmicas

versão revisada de acordo com a resolução CoPGr 6018 de 2011

Orientadora:

Profa. Dra. PATRÍCIA ANGÉLICA ALVES MARQUES

Tese apresentada para obtenção do título de Doutor em Ciências. Área de concentração: Engenharia de Sistemas Agrícolas

Dados Internacionais de Catalogação na Publicação DIVISÃO DE BIBLIOTECA - DIBD/ESALQ/USP

Melo, Leonardo Leite de

Deep learning para Identificação de déficit hídrico em plantas com base em imagens térmicas / Leonardo Leite de Melo. - - versão revisada de acordo com a resolução CoPGr 6018 de 2011 - - Piracicaba, 2021.

a 68

Tese (Doutorado) - USP / Escola Superior de Agricultura "Luiz de Queiroz".

1. Défict hídrico 2. Imagem termal 3. Redes neurais 4. Transfer learn I. Título

DEDICATÓRIA

Dedico este trabalho a Verônica Gaspar Martins Leite de Melo, minha esposa e companheira de longas horas para a realização deste trabalho. Obrigado pela companhia com sol e chuva durante todos os dias e pela compreensão nas longas horas em que tive que me dedicar para tornar este sonho realidade. A meus pais, Moacyr Leite de Melo Filho e Maria Teresa Souto Leite de Melo, e minha irmã, Andressa Leite de Melo, por todo o suporte e confiança dedicadas a mim durante os 30 anos em que almejei um dia alcançar tão honroso título.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por ter me dado saúde, força e dedicação durante toda minha vida para que alcançasse meus objetivos e realizasse o sonho de uma vida. Ao professor José Antônio Frizzone, pelas longas horas de conversas e por sua ajuda durante a condução deste trabalho. Ao professor Rubens Duarte Coelho, pela ajuda durante a definição dos experimentos e análise. À professora Roseli Aparecida Romero, pelos ensinamentos transmitidos e ajuda com a criação do modelo neural. À professora Patrícia Angélica Alves Marques, minha orientadora, por ter acreditado em minhas ideias e pelo apoio incondicional durante todo o curso de doutorado. Agradeço também a Alex Nunes de Almeida, pela ajuda durante os ensaios, e a Timóteo Herculino da Silva Barro, pelo auxílio na avaliação termal, na condução de análise e na avaliação de imagens.

"Se soubéssemos o que estamos fazendo, não seria chamado de pesquisa, seria?"

Albert Einstein

SUMÁRIO

R	ESUMO	8
A	BSTRACT	9
L	ISTA DE FIGURAS	10
T.	ISTA DE TABELAS	11
	ISTA DE ABREVIATURAS E SIGLAS	
	ISTA DE SÍMBOLOS	
1		
2	REVISÃO BIBLIOGRÁFICA	17
	2.1 TERMOMETRIA POR INFRAVERMELHO	
	2.2 ÍNDICE DE ESTRESSE HÍDRICO - CROPWATER STRESS INDEX (CWSI)	18
	2.3 IMAGENS TERMAIS NA DETERMINAÇÃO DO DÉFICIT HÍDRICO	19
	2.4 Cultura da soja	
	2.5 CULTURA DA CANA-DE-AÇÚCAR	
	2.6 TI NA AGRICULTURA	
	2.7 Redes neurais artificiais	
	2.7.1 Histórico	
	2.7.2 Características das redes neurais	
	2.7.3 Rede neural convolucionária (CNN)	
	2.7.4 Arquitetura e treinamento de uma rede neural	
	2.8 Análise de desempenho para sistemas de classificação	34
3	HIPÓTESES	37
4	MATERIAL E MÉTODOS	38
	4.1 Solo	38
	4.2 Manejo da irrigação	
	4.3 ADUBAÇÃO	
	4.4 APLICAÇÃO DE DEFENSIVOS AGRÍCOLAS	
	4.5 TRATAMENTO E DELINEAMENTO EXPERIMENTAL	
	4.5.1 Cana-de-açúcar	48
	4.5.2 Soja	49
	4.6 Criação da base de dados	
	4.7 MONITORAMENTO CLIMÁTICO	
	4.8 Ambiente computacional e treinamento da rede neural	
	4.8.1 Arquitetura computacional	
	4.8.2 Treinamento	
	4.9 AVALIAÇÃO MANUAL POR ESPECIALISTA PARA A CULTURA DA CANA-DE-AÇÚCAR	
	4.10 COMPARAÇÃO ENTRE MÉTODOS	62
5	RESULTADOS E DISCUSSÃO	66
	5.1 CULTURA DA CANA-DE-AÇÚCAR	66
	5.1.1 Avaliação por especialista	66
	5.1.2 Avaliação pelo modelo	
	5.1.3 Comparação das avaliações	
	5.2 CULTURA DA SOJA	
	5.2.1 Avaliação pelo modelo	
	5.3 TREINAMENTO SIMULTÂNEO COM CANA-DE-AÇÚCAR E SOJA	75
6	CONCLUSÕES	77
Þ	EFERÊNCIAS	78

Resumo

Deep learning para identificação de déficit hídrico em plantas com base em imagens térmicas

O uso racional de recursos na agricultura ganhou importância nos últimos anos devido à necessidade de assegurar a sustentabilidade da produção agrícola, de forma a evitar consequências ambientais e até mesmo a iminência de escassez de recursos, como é o caso da água. Pela complexidade de estimar a resposta da planta à disponibilidade hídrica, uma técnica que vem obtendo grande importância é a utilização de imagens térmicas. Porém, o diagnóstico por imagens não é intuitivo e demanda do avaliador conhecimentos físico-químicos do solo e da planta, além de tempo e experiência. Devido a tal limitação, buscaram-se métodos computacionais que possam ser utilizados para realizar essa tarefa, estimando o estado hídrico de plantas a partir de imagens térmicas, suprindo a necessidade de um especialista. Para isso, duas técnicas de eficácia comprovada foram utilizadas: a rede *Inception-Resnet-v2* e a técnica *transfer learning*. Experimentos foram realizados e os resultados obtidos mostram que o sistema de classificação do estresse hídrico na planta desenvolvido, com avaliação a partir da imagem térmica de modo não destrutivo, alcançou um desempenho superior em comparação à avaliação feita por especialista. Além disso, o desempenho foi superior na acurácia global, bem como em sua capacidade de distinguir entre as classes, demonstrando ser uma ferramenta eficaz para a realização de tal tarefa, demandando menor tempo.

Palavras-chave: Manejo de irrigação, Imagem termal, Redes Neurais, Transfer learning

ABSTRACT

Deep Learning for identification of water deficit in plants based on thermal images

Rationing of resources in agriculture has gained focus in recent years, owing to the need to ensure the sustainability of agricultural production, to avoid unfavorable environmental consequences with the imminent scarcity of resources such as water. The use of thermal images to evaluate water availability of plants has been gaining attention recently owing to the complexity of estimating a plant's response to water availability. However, diagnostic imaging is not intuitive and requires evaluator knowledge of the physicochemical properties of the soil and the plant species, in addition to time and experience. To circumvent this limitation, computational methods can be used to perform this task without the requirement of a specialist. The objective of this study was to develop a method to estimate the water availability of sugarcane plants using thermal images, without the need of a specialist. For this, two neural network methods with proven effectiveness were implemented: Inception-Resnet-v2 network and transfer learning technique. Experiments were conducted and the results showed that the developed system achieved superior performance compared to the assessments made by a specialist and aided in classifying the water stress of plant's thermal images in a nondestructive manner. In addition to this overall superior performance in accuracy, the neural network demonstrated a greater ability to distinguish between the classes of thermal stress. Thus, the system developed in this study is a less time-consuming, affordable, and effective tool for estimating the water availability.

Keywords: Irrigation management, Thermal image, Neural network, Transfer learning

LISTA DE FIGURAS

Figura 1. Representação esquemática de um neurônio	28
Figura 2. Representação simplificada de uma rede neural artificial	
Figura 3. Exemplos de rede neurais	33
Figura 4. Área experimental – foto aérea, casa de vegetação e unidades experimentais	38
Figura 5. Unidade experimental (a) área das parcelas, (b) vista lateral da parcela com tens	
para controle da irrigação.	
Figura 6. Amostragem de solo para análise química	40
Figura 7. Teste de uniformidade do sistema de irrigação	
Figura 8. Bateria de três tensiômetros	42
Figura 9. Representação esquemática do sistema de irrigação	
Figura 10. Manejo da irrigação - (a) quadro de válvulas para controle das lâminas, (b) par	cela com
gotejadores, (c) parcela com tensiômetros para monitoramento do solo, (d) rotulação do	
para controle da irrigação, (e) motobomba e medidor de pressão e (f) caixas para fornecia	mento de
água e fertirrigação	46
Figura 11. Elementos do tratamento de adubação para a cultura da soja – (a) fertilizante fra	
(b) aplicação do fertilizante em linha	
Figura 12. Área experimental – (a) exemplo de uma parcela com seu tratamento, (b, c) vi	
da área experimental	
Figura 13. Croqui experimental com a distribuição das parcelas para cana-de-açúcar	
Figura 14. Ensaio com soja, a) soja em floração, b) plantio em área experimental, c) Soja	
vegetativa e d) sistema de irrigação utilizado.	
Figura 15. Croqui do ensaio com a cultura da soja	
Figura 16. Exemplos de imagens termais coletadas nas lâminas de irrigação de (a) 100%, (
(c) 25% da CAD para a cultura da cana-de-açúcar	
Figura 17. Câmara termal FlirOne, utilizada para a criação do banco de dados dos expe	
com cana-de-açúcar e soja	
Figura 18. Exemplo de imagem termal obtida com amostras que receberam os tratam	
100% e 40% da CAD para a cultura da soja	
Figura 19. Software Flir Tools, utilizado para a análise manual das imagens	
Figura 20. PyCharm – ferramenta utilizada para o desenvolvimento do código	
Figura 21. Representação esquemática da arquitetura da rede Inception-Resnet-v2	
Figura 22. Exemplo de área considerada pela rede na avaliação, obtidas no ensaio com	
açúcar	
Figura 23. Gráfico da rede gerado no TensorBoard®	
Figura 24. Exemplos de imagens distorcidas para cana-de-açúcar durante o treinamento	69

LISTA DE TABELAS

Tabela 1. Caracterização química do solo utilizado no experimento4	Ю
Tabela 2. Caracterização físico-hídrica do solo utilizado no experimento4	1
Tabela 3. Valores dos componentes da equação de van Genuchten (1980) para o latossol	lo
vermelhoa, fase arenosa, série Sertãozinho, usado no experimento4	13
Tabela 4. Treinamentos realizados – taxas de aprendizado experimentadas; número de épocas en	m
que o modelo foi treinado; acurácia para o treinamento	8
Tabela 5. Classes de CWSI6	52
Tabela 6. Classes associadas às lâminas aplicadas nesta pesquisa6	52
Tabela 7. Arquitetura da matriz de confusão6	53
Tabela 8. Matriz de confusão para a avaliação por especialista6	59
Tabela 9. Matriz de confusão para a avaliação pela rede neural	⁷ O
Tabela 10. F-score manual e do modelo neural com transfer learning	71

LISTA DE ABREVIATURAS E SIGLAS

AUC Area under curve

CAD Capacidade de água disponível

CNN Convolutional neural network, em Português: Redes neurais convolucionais

CUC Coeficiente de uniformidade de Cristian
CUD Coeficiente de uniformidade de distribuição

DNN Deep Neural Network

LMS Learning Management System
ML Máxima verossimilhança

PCN Pulse-coupled networks
ROC Receiver operating curve
RP Rede profunda

SWN Small world network

PCNN Pulse-coupled neural networks
CWSI Crop Water Stress Index ()

IoT Internet of Things),

VANTs Veículos aéreos não tripulados

RN Redes neurais

GPUs Grafical Processor Units

USGS Serviço Geológico dos Estados Unidos

RNA Rede Neural artificial

LISTA DE SÍMBOLOS

°C Graus Celsius

θcc Umidade volumétrica na capacidade de campo

θpmp Umidade volumétrica no ponto de murcha permanente

θs Umidade volumétrica no ponto de saturação

θr Umidade volumétrica residualψm Potencial matricial da água no solo

Lt Leitura do tensiômetro ou tensão da água no solo

hc Pressão equivalente à altura da coluna d'água no tensiômetro

θ (ψm) Umidade volumétrica em função do potencial mátrico

Li Lâmina necessária para elevar a umidade do solo até a capacidade de campo

mK Millikelvin

θcci Umidade volumétrica na capacidade de campo para a camada i

θi Umidade volumétrica atual estimada para a camada i

Zi Espessura da camada i Ti Tempo de irrigação (h)

A Área da superfície de solo da parcela experimental (m²)

Q Vazão para cada tratamento

Ea Eficiência de aplicação da irrigação (%)

1 INTRODUÇÃO

A sustentabilidade da produção agrícola depende das consequências ambientais do uso de recursos hídricos e terrestres para a produção de alimentos, limitada em todo o mundo por estresses bióticos e abióticos (GARCÍA-TEJERO et al., 2018). O estresse hídrico é de particular importância, uma vez que é o principal fator de estresse abiótico que causa as maiores perdas de rendimentos agrícolas (MARTÍNEZ-ROMERO et al., 2017). A adequada gestão da disponibilidade hídrica no sistema de produção, o fornecimento exato da quantidade de água exigida pelas plantas, a manutenção da umidade do solo em níveis desejados, a economia de recursos como água e energia são encontrados como objeto de estudo de diversos pesquisadores (ELSAYED et al., 2017; GARCÍA-TEJERO et al., 2017, 2018; DIAS-MARTINS et al., 2018; TOSCANO et al., 2018).

Com o intuito de melhorar a gestão de recursos hídricos e a produtividade das culturas, vem crescendo nos últimos anos a utilização de imagens termais para gerar informações. O uso de imagens termais possibilita obter acurácia na determinação de déficit hídrico por meio da análise da imagem coletada (SOBAYO et al., 2018). Porém, a análise dessas imagens não ocorre de forma intuitiva, principalmente quando se leva em consideração a área de contorno do objeto a ser analisado. Com foco nesse problema e na obtenção de imagens termais com melhor segmentação entre o objeto sendo analisado e o ambiente em seu entorno, Chacon et al. (2007) realizaram estudo para determinar qual modelo neural – SWN (*small world network*) ou PCNN (*pulse-coupled neural networks*) – se adequaria melhor a essa tarefa, concluindo que, para os modelos existentes na época, era o PCNN.

Com o propósito de uma avaliação do estresse hídrico de plantas utilizando imagens termais de forma intuitiva, faz-se necessária a criação de um modelo que seja capaz de coletar imagens termais de plantas e realizar sua segmentação separando o objeto a ser analisado do entorno. Esse modelo deve ter foco em soluções que possam avaliar imagens e seus componentes principais e, por fim, ser capaz de classificá-las por meio de sistemas computacionais que realizem essas tarefas como as redes neurais (CHACON et al., 2007).

Redes neurais convolucionais (CNN – sigla de *convolutional neural network*) se adequam perfeitamente ao problema que deve ser resolvido por esse trabalho. Redes neurais convolucionárias são capazes de extrair as características mais relevantes de uma imagem, tais como contornos e ângulos, para então uma posterior classificação (LECUN et al., 1998). Esse modelo de redes neurais convolucionais teve sua concepção em 2012 com a AlexNet (KRIZHEVSKY; SUTSKEVER; HINTON, 2017), e vem se apresentando como um classificador mais preciso de imagens, superando os modelos até o momento existentes na área de reconhecimento de imagens.

Esse tipo de rede vem ganhando espaço em soluções para as mais diversas áreas do conhecimento, sendo utilizada na classificação de imagens, em sistema de recomendação e na área financeira. Propostas para a área agronômica também vêm se mostrando realidade, como o modelo apresentado por Oliveira e Romero (2018), em que a técnica de *transfer learning* foi utilizada sobre o modelo já treinado da rede Inception-ResNet-v2, para que fosse capaz de identificar frutos de cacau em ponto de colheita.

Modelos computacionais já vêm sendo utilizados no setor agrícola há algum tempo, como o uso para determinação da viabilidade econômica da adoção de um sistema de irrigação para uma determinada cultura (MARQUES et al., 2006), de acordo com os autores, modelos computacionais se destacam por ser uma das mais importantes ferramentas tecnológicas no auxílio à adoção de uma cultura irrigada, com a finalidade de permitir a eficiência e estabilidade na produção agrícola.

Este trabalho possui duas hipóteses primárias: a) que redes neurais convolucionais podem ser treinadas para avaliar imagens termais e inferir se uma planta está sob estresse hídrico e b) que redes neurais convolucionais podem substituir métodos agronômicos clássicos, provendo assim uma ferramenta eficaz para monitoramento da água na planta sem exigir infraestrutura complexa. Tem como objetivo desenvolver um modelo computacional que seja capaz de analisar imagens termais de plantas e determinar se estão sob estresse hídrico por meio da utilização de redes neurais convolucionais, bem como apresentar e armazenar tais avaliações. A importância desta pesquisa está na possibilidade de racionalizar o uso de água por meio do manejo da irrigação, gerando maior produtividade, bem como de prover um modo mais amigável de determinação do status hídrico de uma planta quando comparado aos mecanismos tradicionais. E como principal vantagem, não há necessidade de destruição de material vegetal e nem coleta de solo, permitindo agilidade e maior número de pontos de avaliação.

2 REVISÃO BIBLIOGRÁFICA

Nesta revisão, serão abordados os aspectos gerais (histórico, fisiologia, irrigação, tecnologia da informação, análise de dados e redes neurais profundas), as relações hídricas, o índice de estresse hídrico, o treinamento de redes neurais e a avaliação de desempenho de sistemas de classificação.

2.1 Termometria por infravermelho

Termometria por infravermelho possibilita estimar a temperatura de um corpo através de radiômetros, que medem a energia na faixa do infravermelho (CAMPBELL; NORMAN, 1998). Os equipamentos de temperatura por infravermelho são equipados com sensores de captação de energia em forma de raios infravermelhos, emitida pela superfície de um objeto, e podem variar em função da sua temperatura. Representando a temperatura como uma resposta às trocas de energia, a superfície da cobertura vegetal pode ser expressa em termos da radiação por ela emitida. Assim, conhecendo-se o fluxo de radiação emitido pela superfície do corpo, pode-se determinar sua temperatura (MAGIOTTO, 1996).

Entre as vantagens da termometria por infravermelho, estão a relativa facilidade de uso, a rapidez nas medições e o fato de ser um método não destrutivo, sendo assim adequado para a medição da temperatura foliar. Corpos com temperatura acima de zero absoluto emitem radiação térmica, e a intensidade da emissão de energia depende somente da temperatura e da natureza da superfície emitente (GADE; MOESLUND, 2014). Câmeras térmicas foram desenvolvidas inicialmente para fins militares e, com o barateamento da tecnologia, passaram a ser utilizadas em diversos campos de pesquisa, destacando-se o setor agrícola, por apresentar rápida resposta, aliada à facilidade de operação. O barateamento dos equipamentos e desenvolvimento de leitores portáteis, como canhões térmicos e câmeras, no início dos anos 70, impulsionou as pesquisas sobre o uso desta técnica para a medição da temperatura do dossel vegetativo sem que haja contato com a folha da planta e sobre a detecção de ocorrência de estresse hídrico (GARCIA et al., 2000).

2.2 Índice de estresse hídrico - Crop Water Stress Index (CWSI)

Jackson et al. (1981), combinando a equação do balanço de energia e a equação de Penman Monteith, apresentaram as considerações teóricas para o desenvolvimento do *Crop Water Stress Index* (CWSI) baseado na diferença entre a temperatura foliar e a temperatura do ar e comparando essa diferença em condições de déficit hídrico severo (linha base superior) e de ausência de limitação de água (linha base inferior).

Jackson (1982), na revisão sobre temperatura foliar e cobertura vegetal como indicador do estresse hídrico na planta, apresenta obras cujos autores argumentaram que a temperatura das folhas é sempre maior que a temperatura do ar circundante, ou que as folhas podem tornar-se muito mais frias que o ar. O primeiro argumento prevaleceu por vários anos, com numerosas citações apresentando como evidência que a temperatura das folhas não é um sensível indicador de estresse hídrico. Em outra vertente, autores argumentam que as temperaturas da cobertura vegetal podem ser utilizadas com indicativo do estresse hídrico. A validação de sua adequabilidade se tornou factível devido ao avanço da tecnologia para a determinação da temperatura, possibilitando a comprovação de sua eficácia na detecção do estresse hídrico, e mesmo na estimativa da evapotranspiração, apesar de existirem ainda muitos pontos de discussão.

Trentin (2010) argumenta que, em plantas de cana-de-açúcar sob estresse hídrico, os estômatos permanecem fechados e a transpiração diminui de modo que a temperatura foliar apresenta um determinado incremento de temperatura, ficando entre 4º e 6ºC mais elevada do que a temperatura do ar, e o CWSI fica próximo a 1. Já quando em equilíbrio hídrico, a temperatura foliar é de 1º a 4ºC mais baixos do que a temperatura do ambiente e, nesse caso, o CWSI é igual a zero.

Não limitando a utilização de dados meteorológicos para a determinação das linhas base superior e inferior, como apresentado por Jackson et al. (1981), apresentando uma metodologias alternativa que utilizam os parâmetros de solo para sua determinação, nos quais o limite superior experimental do estresse hídrico máximo tolerado pela cultura ocorre quando os estômatos estariam completamente fechados e o limite inferior é a condição na qual a planta está sem nenhuma restrição hídrica. Assim, sua determinação pode ser realizada experimentalmente por meio da indução do solo ao ponto de murcha permanente. De acordo com o proposto por Jackson et al. (1981), o índice de estresse hídrico para a cultura estará compreendido entre 0 (estresse nulo) e 1 (estresse máximo). Já Jesus et al. (2015) utilizaram a maior e a menor temperatura em relação à do ar e à temperatura da planta para definir as linhas base superior e inferior. Encontraram altos valores de correlação entre o CWSI calculado com as linhas base estimadas pelas equações de Jackson et al. (1981).

Também se podem encontrar propostas para a substituição dos limites teóricos, inferior e superior, por meio de medições de temperatura em superfícies de referência. Moller et al. (2007) adotaram painéis artificiais molhados, feitos com espuma de poliestireno revestida com uma mistura de poliéster e viscose, para obter o limite inferior. Wang et al. (2005), para a determinação do limite superior, cobriram a folha com uma camada de resina, que obstrui os estômatos, eliminando a transpiração.

2.3 Imagens termais na determinação do déficit hídrico

A água é um dos recursos de suma importância durante o processo de transformação da energia luminosa em fotoassimilados, tornando-se componente indispensável durante o manejo agrícola de forma a atingir altos índices de produtividade. A água constitui, em geral, cerca de 90% do peso das plantas e participa de todos os processos bioquímicos e morfológicos, além de ser responsável pela manutenção da turgescência, atuando como reagente em importantes reações na planta, como a fotossíntese (TAIZ; ZEIGER, 2015; WU et al., 2016). Segundo Jackson et al. (1988), a temperatura foliar é um método indireto para monitorar o estresse de água das plantas, fundamentado na hipótese de que a transpiração resfria as folhas em relação ao ar adjacente. À medida que a água se torna limitante, a transpiração é reduzida e, em consequência, ocorre aumento da temperatura foliar pela absorção da radiação solar incidente. Assim, a água possui um papel fundamental na regulação térmica da planta, agindo tanto no resfriamento, como na manutenção e na distribuição do calor (GARCÍA-TEJERO et al., 2011; TAIZ; ZEIGER, 2015).

À medida que os estômatos se fecham em resposta à depleção de água no solo e à diminuição da absorção de água pelas raízes, a temperatura da planta e a transferência de energia convectiva aumentam para equilibrar a diminuição da transpiração (YU et al., 2015). Os estômatos fechados ou parcialmente fechados influenciam na redução da absorção de CO₂ ou na regulação, permitindo que a planta se adapte rapidamente às mudanças de estímulos bióticos e abióticos (BLONQUIST et al.., 2009; ZHAO et al., 2017), que, por sua vez, impactam diretamente na produtividade final da cultura (VIÇOSI et al., 2017).

O uso de imagens termais para investigar, identificar e monitorar o estresse hídrico durante o ciclo de uma cultura permite ao agricultor/pesquisador utilizar uma ferramenta de auxílio à gestão da água de forma a evitar declínios no rendimento pela variabilidade da disponibilidade hídrica (GARCÍA-TEJERO et al.., 2016). Dessa forma a temperatura foliar depende do balanço de energia, a forma como as folhas absorvem parte da radiação presente no ambiente (ondas curtas

e a maior parte ondas longas), vem sendo utilizada como um monitor do status da água na planta (TAIZ. ZEIGER, 2015; DEERY et al., 2016).

Tecnologias de sensoriamento de culturas apresentam grande potencial como ferramentas para monitoramento da quantidade de água presente nas plantas, possibilitando a previsão de produtividade, auxiliando na eficiência do uso desse recurso e no gerenciamento preciso da irrigação (CRAPARO et al., 2017; O'SHAUGHNESSY et al., 2011). Informações úteis para a tomada de decisão durante o manejo da cultura podem ser obtidas por meio da termografia de infravermelho, esse tipo de imagem vem sendo utilizada na agricultura como ferramenta de imagem não invasiva e versátil para investigar estresses bióticos (pragas e doenças), e abióticos (déficit de nutrientes e água), além de contribuir para monitoramento de possíveis obstruções em sistema de irrigação (O'SHAUGHNESSY et al., 2011).

Diversos estudos apontam a utilização de termografia como uma das técnicas mais promissoras nos diagnósticos de problemas no setor agrícola. Chaerle et al. (2007) utilizaram imagens termais combinadas de fluorescência térmica da clorofila para estudar a heterogeneidade espacial e temporal da transpiração foliar e a fotossíntese para identificação de respostas préestomáticas e doenças causadas por fungos e bactérias. Stoll et al. (2008) ressaltam o uso da câmera termal para observar respostas das variações dos padrões termais na cultura da videira, infectada com um fungo antes do aparecimento dos sintomas visíveis. Posteriormente, Bulanon et al. (2009) combinaram imagens digitais e térmicas obtidas da mesma área com o objetivo de melhorar a identificação de frutos para colheitadeiras robóticas.

TESTI et al. (2008) concluíram que, sob outras condições ambientais, uma planta sob estresse hídrico apresenta temperatura foliar superior quando comparada à cultivada sob condições plenas de disponibilidade hídrica. Iaffe et al. (2003) avaliaram a utilização de imagens infravermelho como indicativo da recuperação do potencial da folhagem de cafeeiros irrigados e não irrigados durante a floração e obtiveram a diferença de temperatura da folhagem e do ar com indicativo das parcelas segundo seu déficit hídrico.

A prática da irrigação é uma alternativa para o incremento da produtividade (até 40%) sem a expansão da área de plantio, contribuindo para diminuir o desmatamento – como o caso da Floresta Amazônica, cujas principais causas de desmatamento são a abertura de novas áreas para a produção de soja (GAVA et al., 2015). O desafio da agricultura irrigada é produzir alimentos sem desperdício de insumos, utilizando a água de forma eficiente, ou seja, ser capaz de aumentar a produção e a produtividade de forma sustentável. Nesse contexto a irrigação associado a técnicas como a termografia que propiciem melhorias e economia de água destacam-se como ferramentas disruptivas no setor agrícola.

A produção de alimentos, com alto aproveitamento da água, é possível de ser alcançada pela combinação de um manejo agronômico eficiente e o auxílio de ferramentas tecnológicas de alta precisão e exatidão na determinação dos parâmetros fisiológicos das culturas durante todo o seu ciclo, de forma a impossibilitar a ocorrência de estresses fisiológicos, que possam prejudicar a eficiência produtiva individual de cada planta (LOPES et al., 2017). Pode-se notar a redução da disponibilidade hídrica no setor agrícola nos últimos anos, ocasionado pela expansão de áreas de cultivos, que passam a ocupar áreas antes de florestas e demandar mais água para seu cultivo, resultando em um cenário passível de ocorrências de escassez hídrica. Essa escassez, em certas regiões associada às transições climáticas bruscas, acaba por inviabilizar o plantio de algumas culturas mais sensíveis ao estresse hídrico, podendo-se utilizar como exemplo a cultura do tomate (DUARTE et al., 2014).

2.4 Cultura da soja

Nos últimos anos, poucos países cresceram tanto quanto o Brasil no comércio internacional de agronegócios (LOPES et al., 2017). O Brasil é o maior produtor mundial do grão de soja, de acordo com boletim da CONAB (2020), a produção nacional de soja atingiu área plantada de 36,950 milhões de hectares, com produção de 124,845 milhões de toneladas. A expectativa de venda para o mercado externo está em torno de 82,7 milhões de toneladas para este ano de 2021, sendo que já foram exportados no período de janeiro a outubro 81,4 milhões de toneladas. Para o ano de 2022, são esperadas cerca de 85 milhões de toneladas, o que representaria aumento de 2,78% em relação à safra deste ano.

A soja (Glycine Max (L.) Merrill.) é uma planta resistente ao estresse hídrico, desde que essa condição não ocorra em estádios críticos do ciclo da planta (GAVA et al., 2016). Assim, são necessários a identificação e o monitoramento da ocorrência de déficit hídrico nas diferentes fases fenológicas da cultura em campo. De acordo com os autores, a deficiência hídrica no início do ciclo da soja causa forte redução na emissão de novos ramos, reduzindo potencialmente o número de nós que iriam produzir vagens. Porém, a planta pode se recuperar parcialmente, caso haja melhor disponibilidade de água após o florescimento, podendo emitir e fixar um número maior de flores nos novos nós para produzir legumes, podendo ainda reduzir a formação de novas folhas para sustentar o enchimento de grãos.

Quando ocorre boa disponibilidade de água no período vegetativo, mas com déficit hídrico no florescimento e início de formação dos legumes, caracteriza-se uma situação dramática para a cultura, sendo esse o período mais sensível da planta ao déficit hídrico. Os efeitos se darão

sobre o abortamento de flores, óvulos e legumes, e, posteriormente, sobre o tamanho dos grãos. Dessa maneira, o monitoramento das necessidades hídricas da cultura da soja durante seu ciclo se torna essencial para garantir altos índices de produtividade (GAVA et al., 2015).

2.5 Cultura da cana-de-açúcar

O Brasil é o maior produtor mundial de cana-de-açúcar, sendo que São Paulo responde por 55% da área plantada no país. O crescimento da demanda mundial por etanol, aliado às grandes áreas cultiváveis e condições edafoclimáticas favoráveis à cana-de-açúcar, tornam o Brasil um participante na comercialização mundial com elevada competitividade. A safra nacional 2018/19 de cana-de-açúcar atingiu um total de 8.382,2 mil hectares de área colhida, com produtividade média de 72.234 kg ha⁻¹ em 2018/2019, representando uma redução de 2,4% em relação ao obtido na temporada passada (CONAB, 2019). São Paulo obteve redução na área colhida de 181,5 mil hectares em comparação com a safra anterior. Muitas dessas áreas, que até então eram ocupadas com cana-de--açúcar, apresentaram expansivo aumento do plantio de soja.

A cana-de açúcar (*Saccharum officinarum* L.) é uma planta perene própria de climas tropicais e subtropicais, adaptada a ambientes com alta intensidade luminosa e térmica (AZEVEDO et al., 2011). O ambiente ideal para a cana-de-açúcar é aquele com duas estações distintas, uma quente e úmida, quando a chuva (ou irrigação) é bem distribuída durante a estação de crescimento para proporcionar a germinação, perfilhamento e desenvolvimento vegetativo, seguida de outra fria e seca, quando o período de pré-colheita é relativamente seco e as horas de sol são abundantes durante toda a temporada, para promover a maturação e consequente acúmulo de sacarose nos colmos (CAPUTO et al., 2008; JAMES, 2004). Assim, a cana-de-açúcar é cultivada desde o nível do mar até 1.500m e entre as latitudes compreendidas entre os paralelos 35º de latitude norte e sul (CAPUTO et al., 2008).

A morfologia da planta é composta por colmos, folhas, raízes e flores. Cada um tem um papel importante no crescimento, no amadurecimento e na produção da cultura. A propagação vegetativa da cana-de-açúcar é, normalmente, feita por toletes contendo uma ou mais gemas – colmos em miniatura contendo nós, entrenós e primórdios de raiz e de gema, que se desenvolvem para produzir outros colmos – chamados perfilhos nas fases iniciais de desenvolvimento. O perfilhamento acontece após a brotação das gemas. Por último, há o processo de formação da inflorescência, quando a cana deixa de produzir folhas e colmos (DINARDO-MIRANDA et al., 2008; JAMES, 2004; MOORE e BOTHA, 2014).

2.6 TI na agricultura

Há décadas, a tecnologia tem contribuído com diversas soluções disruptivas que modificam a auxiliam os processos nos mais diversos setores da indústria. No caso da agricultura, surgiram, na década de 90, os primeiros sensores e GPS embarcados nos maquinários agrícolas com o objetivo de maximizar ganhos de produtividade. O setor agrícola passou por muitas evoluções desde então até alcançar, nos dias de hoje, a denominada Agricultura 4.0 (LUCAS, 2019).

No início da atividade agrícola, após o abandono da vida nômade pelo homem, as técnicas agrícolas eram primitivas e manuais limitando a produtividade. Ao passar do tempo, o trabalhador rural foi agregando ao manejo ferramentas que facilitavam e aceleravam a produção. Até o século 18, era predominante o uso de bois e cavalos como força de tração de arados de madeira. A semeadura era feita à mão; o cultivo, com enxadas, técnicas que limitavam bastante a produtividade. A grande evolução se deu em resultado da Revolução Industrial, no século 18, a qual foi responsável por gerar grandes indústrias nas metrópoles, mas também contribuiu para a criação de tecnologias aplicadas ao trabalho rural. À época, eram enormes veículos movidos a vapor, que podiam chegar a pesar cerca de 20 toneladas. Eles podiam elevar significativamente a agilidade na realização de tarefas (LUCAS, 2019).

Esse processo de inserção de máquinas na agricultura ficou conhecido como Mecanização do Campo. Os novos tratores que substituíram os enormes modelos movidos a vapor eram, então, os responsáveis por rebocar e reabastecer semeadeiras, colheitadeiras, pulverizadores, entre outras máquinas, que aumentaram a produção em um nível nunca antes visto. Assim, a mecanização passou a acompanhar o trabalhador rural em todas as etapas do ciclo produtivo, desde a preparação do solo até a manutenção da lavoura e a colheita (MATTHEWS et al., 2017).

Com o advento da internet, a partir dos anos 90, as Tecnologias de Informação (TI) se expandiram exponencialmente, uma vez que o potencial de integração evoluiu de modo antes inimaginável. O resultado foi a criação de uma série de sistemas e plataformas que elevaram a produtividade em diversos campos, inclusive na agricultura (LUCAS, 2019). O crescimento populacional e as mudanças climáticas são responsáveis por exigir do setor agrícola abordagens e tecnologias mais precisas e eficientes para garantir o suprimento adequado e regular de alimentos para a sociedade com menor consumo de recursos natural em especial a água.

A Agricultura 4.0 surge dessa conjuntura de escassez de recursos, como uma gestão que busca – por meio de tecnologias como *Big Data*, Internet das Coisas (IoT, sigla para *Internet of Things*), inteligência artificial, aprendizado de máquina e modelagem probabilística avançada – fornecer às plantas e animais exatamente o quê e quando precisam, aumentando a produtividade e maximizando o uso dos recursos disponíveis de forma sustentável. A Agricultura 4.0 refere-se a

um conjunto de tecnologias digitais e de ponta integradas e conectadas por meio de softwares, sistemas e equipamentos capazes e otimizar a produção agrícola, em todas as etapas. As operações e decisões passam a ser orientadas com base em dados sobre solo, clima, atmosfera e as culturas de interesse agrícola (LUCAS, 2019).

Outro ponto a destacar refere-se à evolução e à tendência de barateamento dos veículos aéreos não tripulados (VANTs). Nos últimos anos, sua aplicação em diversas áreas vem se tornando cada vez mais viável economicamente. Na agricultura, em que boa parte do processo de inspeção e colheita é realizada por humanos, o uso dessa tecnologia pode auxiliar no mapeamento, no monitoramento e na proteção de frutos (PEDERI; CHEPORNIUK, 2015). Também tem crescido o número de estudos sobre o seu uso cooperativo, em uma vasta gama de aplicações civis – como vigilância de área (WAHARTE; TRIGONI, 2010), monitoramento de incêndios em florestas (CASBEER et al., 2005) – e militares – como modificação de sinais de radar (MAITHRIPALA; JAYASURIYA; MEARS, 2007) e ludíbrio de mísseis terra-ar (DURO; FRANKLIN; DUBÉ, 2012), onde são explorados os benefícios de se ter mais de um drone trabalhando em conjunto.

Uma das limitações dos VANTs é a baixa autonomia, devido à alta demanda dos motores, principalmente em casos em que o veículo precisa carregar equipamentos, como câmeras. Assim, o uso em grandes regiões, como uma área agrícola completa, pode se tornar inviável, uma vez que não seriam capazes de percorrer um talhão, que possui em média 25.000 metros quadrados, em voos em baixas altitudes, necessários para capturar detalhes das folhas para inspeção. Nesse cenário, o uso de múltiplos robôs que se comunicam e cooperam para cobrir regiões complementares mostra-se uma solução promissora em aplicações dessa área (PEDERI; CHEPORNIUK, 2015).

2.7 Redes neurais artificiais

Este capítulo apresenta o histórico e os conceitos sobre redes neurais utilizados durante o desenvolvimento deste trabalho.

2.7.1 Histórico

A era das redes neurais (RN) iniciou com o trabalho pioneiro de McCullock (psiquiatra e neuroanatomista) e Pitts (matemático), em 1943, apresentando um modelo capaz de simular o comportamento dos neurônios: "A Logical Calculus of the Ideas Immament in Nervous Activity" (MCQUEEN et al., 1995). Foram propostas redes lógicas de neurônios, desenvolvendo novas ideias sobre máquinas de estados finitos, elementos de decisão de limiar lineares e representações lógicas de várias formas de comportamento e memória. Assim, foi possível demonstrar que, com um número suficiente de unidades simples e um conjunto de conexões sinápticas operando sincronicamente, uma rede assim constituída calcularia, em princípio, qualquer função computável (MCQUEEN et al., 1995; CANZIANI, PASZKE, CULURCIELLO, 2016).

O primeiro trabalho com ligação direta ao aprendizado de máquina foi o livro de Hebb, em 1949, "The Organization of Behavior". Hebb propôs uma teoria para explicar o aprendizado em neurônios biológicos baseada no reforço das ligações sinápticas entre neurônios excitados. Em 1958, Frank Rosenblatt demonstrou, com o seu novo modelo, o perceptron (um classificador linear), que, se fossem acrescidas sinapses ajustáveis, as RNA (Redes Neurais Artificiais) com várias camadas de perceptrons poderiam ser treinadas para classificar certos tipos de padrões (CANZIANI; PASZKE; CULURCIELLO, 2016; HEBB, 1949).

Em 1960, Widrow e Hoff sugeriram uma regra de aprendizado, conhecida como regra LMS (learning management system) ou regra Delta, dando origem a rede ADAptive LINear Element, posteriormente ADAptive LInear NEuron, que ainda hoje é conhecida com o nome de Adaline. Em 1962, Widrow apresentou sua versão com múltiplos elementos, Multi ADAptive LINear Element Madaline, que se trata de uma serie de Adalines interconectadas. Em 1965, foi publicado o livro de Nilsson – "Learning Machines" –e é até hoje o livro mais aclamado sobre padrões linearmente separáveis(WIDROW 1962; WIDROW; HOFF, 1960). Em 1967, utilizou-se gradiente estocástico para classificação de padrões adaptativos (AMARI, 1998). Em 1969, Minsky e Paper utilizaram matemática para mostrar que, para algumas tarefas específicas, o perceptron não era capaz de executar com eficiência (CANZIANI; PASZKE; CULURCIELLO, 2016).

Nos anos 70, a abordagem conexionista ficou estagnada, apesar de alguns pesquisadores continuarem trabalhando. Em 1982, J. Hopfield publicou um artigo "Neural networks and physical

systems with emergent collective computational abilities" que foi responsável pela retomada de pesquisas na área. Ele mostrou a relação entre redes recorrentes autoassociativas e sistemas físicos. Redes neurais são modelos de computação com propriedades particulares, como aprender, generalizar, agrupar ou organizar dados. São constituídas de estruturas distribuídas formadas por um grande número de unidades de processamento bastante simplificadas conectadas entre si. O comportamento inteligente se dá pelas interações das unidades de processamento da rede (CANZIANI; PASZKE; CULURCIELLO, 2016).

Após seu surgimento, pode-se assumir que a área de redes neurais passou por três períodos, sendo o primeiro o das redes totalmente conectadas, conhecidas como cibernética, quando foram apresentados o perceptrom e a Adaline. Posteriormente, surgiram as redes neurais conexionistas, nas quais mais de uma Adaline são agrupadas para simular o comportamento do cérebro, e por último as redes profundas (RP), que se propagam até os dias de hoje, redes estas compostas por inúmeras camadas, capazes de realizar inferência sobre conjuntos de dados desde que previamente treinadas. Devido à sua característica de ser totalmente conectada, esse tipo de rede implica em tempo quadrático para seu treinamento. Com o crescimento do volume de dados disponíveis para treinamento, este tipo de rede se tornou inviável, (ROSENBLATT, 1958).

As primeiras redes neurais a obterem ampla repercussão foram baseadas em prétreinamento não supervisionado (HINTON, 2006). Entretanto, foi o redescobrimento das redes neurais convolucional (CNN) (LECUN et al., 1998) que tornou esse tema um dos principais tópicos em aprendizado de máquina e tecnologias de processamento paralelo em GPUs (*Grafical Processor Units*); e grandes bases de dados permitiram que essas redes fossem usadas plenamente. A utilização de GPUs auxilia no processo de treinamento de redes neurais pelo fato de estas apresentarem um grande número de núcleos de processamento, o que facilita a execução em paralelo de múltiplos processos computacionais. Todavia, mesmo com o uso de GPUs, o treinamento pode levar algumas semanas para finalizar (OLIVEIRA; ROMERO, 2018).

Redes neurais convolucionais se caracterizam por serem capazes de extrair dados representativos de uma imagem. Em 2012, pela primeira vez, uma CNN foi usada para esse propósito (KRIZHEVSKY; SUTSKEVER; HINTON, 2017), tendo vencido o desafio com um erro de apenas 15%, sendo 10% superior ao modelo conhecido como estado da arte na área de reconhecimento de imagens até o momento. Esse resultado intrigou a comunidade científica de visão computacional, tornando assim as redes neurais profundas (que possuem inúmeras camadas) o padrão em classificação de imagens e dando origem ao reconhecimento a essa área.

Com bom desempenho sendo demonstrado, outras áreas do conhecimento, além da área da computação, vêm utilizando esses modelos para os mais diversos fins, como análise de crédito

no mercado financeiro, auxílio no diagnóstico médico, criação de veículos autômatos entre outros inúmeras aplicações. A aplicação de redes neurais vem se mostrando realidade na área das ciências agrárias desde os anos 90. McQueen et al. (1995), fizeram a investigação da utilização de técnicas de aprendizado de máquina existentes na época para alguns problemas na agricultura e horticultura e apresentaram um estudo de caso para inferência de regras de manejo para algumas plantas invasoras.

Pesquisas recentes vêm utilizando redes do tipo PCN (*pulse-coupled networks*) para a separação de grãos de trigo e para a avaliação das características físicas do solo e do crescimento das culturas, concluindo, após os experimentos em campo, que o modelo desenvolvido foi capaz de auxiliar na escolha da cultura que mais se adequava ao solo avaliado (REASHMA; PILLAI, 2018; CHACON et al., 2007).

Trabalhos que envolvem não somente dados agronômicos, mas também outras tecnologias, vêm sendo desenvolvidos, como a classificação de áreas de manejo utilizando imagens de satélite (DURO; FRANKLIN; DUBÉ, 2012). No contexto da utilização de redes neurais para a agricultura, e em consequência do barateamento dos recursos computacionais aliado aos novos sensores que estão sendo desenvolvidos, apresentam-se propostas que utilizam cada vez mais recursos tecnológicos de ponta. Imagens de câmeras termais foram utilizadas juntamente a redes neurais convolucionais para a determinação da umidade presente no solo com o intuito de monitorar os fatores que possam prejudicar o desenvolvimento da cultura, como a falta de água, chegando à conclusão de que o modelo proposto é capaz de realizar tal tarefa com alto grau de acurácia (SOBAYO et al., 2018).

Com o aumento da utilização de tais tecnologias, multiplicam-se trabalhos que visam facilitar a implantação e utilização de redes neurais previamente definidas em novos domínios. Nessas técnicas, conhecidas como "transfer learning" modelos já treinados são utilizados e estendidos com o treinamento de novas classes. Oliveira e Romero (2018), utilizando a técnica aplicada à rede Inception-ResNet-v4 para a identificação de frutos de cacau em ponto de colheita, concluem que, após o treinamento, a rede foi capaz de identificar os frutos maduros com 89% de precisão.

2.7.2 Características das redes neurais

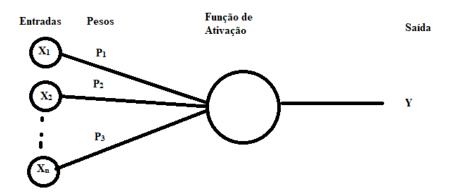
Uma rede neural artificial é formada por várias unidades de processamento independentes que representam neurônios; cada uma dessas unidades é composta por entradas (axiomas), uma função de ativação (neurônio) e uma saída (dendrito) (Figura 1).

As redes neurais artificiais são modelos que buscam simular o processamento de informação do cérebro humano. São compostas por unidades de processamentos simples, os

neurônios, que se unem por meio de conexões sinápticas. De uma forma simplificada, uma rede neural artificial pode ser vista como um gráfico em que os nós são os neurônios e as ligações fazem a função das sinapses, como exemplificado na Figura 2 (MCCULLOCH; PITTS, 1943).

O comportamento das conexões entre os neurônios é simulado por meio de seus pesos. Os valores de tais pesos podem ser negativos ou positivos, dependendo de as conexões serem inibitórias ou excitatórias. O efeito de um sinal proveniente de outro neurônio é determinado pela multiplicação do valor (intensidade) do sinal recebido pelo peso da conexão correspondente (xi pi). É efetuada a soma dos valores xi pi de todas as conexões, e o valor resultante é enviado para a função de ativação, que define a saída (y) do neurônio (HAYKIN, 2001, p. 36). Combinando diversos neurônios, forma-se uma rede neural artificial.

Figura 1. Representação esquemática de um neurônio



A representação de um neurônio é composta por três elementos básicos: um conjunto de n conexões de entrada (x1, x2, ..., xn); pesos associados a cada conexão (p1, p2, ..., pn); uma função de ativação (M) que limita o intervalo permissível de amplitude do sinal de saída (y) a um valor fixo.

Fonte: Elaborado pelo autor.

Entradas Camadas internas Saida

Figura 2. Representação simplificada de uma rede neural artificial

Fonte: Elaborado pelo autor.

Existem duas formas básicas de aprendizado de redes neurais: aprendizado supervisionado e aprendizado não supervisionado (HAYKIN, 2001): no aprendizado supervisionado, um agente externo (professor) apresenta à rede neural alguns conjuntos de padrões de entrada e seus correspondentes padrões de saída. Portanto, é necessário ter um conhecimento prévio do comportamento que se deseja ou se espera da rede. Para cada entrada, o professor indica explicitamente se a resposta calculada é boa ou ruim. A resposta fornecida pela rede neural é comparada à resposta esperada. O erro verificado é informado à rede para que sejam feitos ajustes a fim de melhorar suas futuras respostas.

Já na aprendizagem não supervisionada, ou aprendizado auto supervisionado, não existe um agente externo para acompanhar o processo de aprendizado. Nesse tipo de aprendizagem, somente os padrões de entrada estão disponíveis para a rede neural. A rede processa as entradas e, detectando suas regularidades, tenta progressivamente estabelecer representações internas para codificar características e classificá-las automaticamente. Este tipo de aprendizado só é possível quando existe redundância nos dados de entrada, para que se consiga encontrar padrões em tais dados.

A habilidade de um ser humano de realizar funções complexas e principalmente a sua capacidade de aprender, advêm do processamento paralelo e distribuído da rede de neurônios do cérebro. Os neurônios do córtex, a camada externa do cérebro, são responsáveis pelo processamento cognitivo. Um novo conhecimento ou uma nova experiência pode levar a alterações estruturais no cérebro. Tais alterações são efetivadas por meio de um rearranjo das redes de neurônios, reforçando ou inibindo algumas sinapses (HAYKIN, 2001).

2.7.3 Rede neural convolucionária (CNN)

Redes neurais se tornaram famosas por serem capazes de, após um período de treinamento supervisionado, receberem em sua camada de entrada dados de um ambiente externo e realizar sua classificação. Porém, tal característica se deu após o desenvolvimento de redes mais avançadas, como as redes neurais profundas (*deep neural network* – DNN), caracterizadas por seu grande número de camadas, enquanto as redes CNNs são um tipo de rede profunda (DURO; FRANKLIN; DUBÉ, 2012).

Elas podem produzir boa generalização, com várias camadas intermediárias, ainda que seu treinamento seja estritamente supervisionado. Essas redes foram apresentadas pela primeira vez em 1988 (ATLAS; HOMA; MARKS, 1988). Foram aprimoradas por LeCun et al. (1998) e generalizadas por Behnke (2003). As primeiras redes neurais profundas a obterem ampla repercussão foram as baseadas em pré-treinamento não supervisionado (HINTON, 2006). Entretanto, foi o redescobrimento das redes neurais convolucionária (CNN) que tornou esse tema um dos principais tópicos em aprendizado de máquina (LECUN et al., 1998). Porém, o desenvolvimento de tais modelos só se tornou possível devido à evolução das tecnologias de processamento paralelo em GPUs, e grandes bases de dados permitiram que essas redes fossem usadas plenamente.

Esse tipo de rede difere das redes profundas clássicas por sua camada convolucionária, que é capaz de extrair características relevantes das imagens analisadas, justificando assim sua ampla utilização nas tarefas de detecção, segmentação e reconhecimento de objetos, reconhecimento de faces (TAIGMAN et al., 2014; LIU, DENG, YANG, 2018), expressões faciais (YU et al., 2015), detecção de placas de trânsito (CIRESAN et al., 2012), de texto e de pedestres (TOMPSON et al., 2015) em imagens naturais.

Outro fator que impulsionou fortemente o desenvolvimento das CNNs foi o aumento dos dados disponíveis para seu treinamento, devido ao grande volume de dados gerados pela internet, smartphones, redes sociais, sensores entre outros. Porém, para que uma CNN seja capaz

de aprender a realizar inferência sobre uma imagem, necessita de exemplos previamente rotulados para seu treinamento, o que em muitos casos pode ser um limitante. Dados rotulados fazem-se necessários para um treinamento supervisionado e para que a rede convolucional seja capaz de extrair características relevantes de uma imagem que posteriormente possam ser relacionadas a uma determinada classe (DONAHUE et al., 2013).

Redes convolucionais também se destacam por serem capazes de extrair características relevantes de uma imagem gerando o mapa de características. Um mapa de características é obtido aplicando repetidamente uma função sobre sub-regiões da imagem completa, isto é, realizando convolução da imagem de entrada com um classificador linear, adicionando um termo bias (representação do erro sistemático) e aplicando uma função não linear (SZEGEDY et al., 2015). Como resultado do treinamento de uma CNN, obtém-se uma matriz de pesos de todas as camadas escondidas, representados por um tensor tetradimensional, contendo elementos para cada mapa e características de origem e destino mais um bias, sendo representado como um vetor contendo um elemento para cada mapa de características de destino

Em geral, uma camada convolucional é implementada como muitas "sub-layers", cada uma com um filtro diferente e centenas de diferentes filtros de suas entradas podem ser usadas em uma camada convolucionária. Os resultados dessas convulações são disponibilizados para a próxima camada (OLIVEIRA; ROMERO, 2018).

Alguns exemplos de redes convolucionais que se tornaram famosas nos últimos anos são Alex Net e GoogLeNet. A primeira é uma arquitetura proposta por YannLeCun, famosa família de redes convolucionais, com bons resultados na classificação de dígitos numéricos, manuscritos ou impressos. Foi treinada com a base de dados de digitalizações de códigos postais provenientes de correspondências verdadeiras do serviço postal de Buffalo - NY nos Estados Unidos, suplementadas por dígitos impressos com diferentes fontes, produzindo em sua camada de saída dez unidades, correspondentes a cada um dos dígitos que podem ser reconhecidos (classes). A GoogLeNet é um modelo usado no Google Deep Dream para a classificação de imagens, códigofonte, em Python, é livre e está disponível no GitHub.

2.7.4 Arquitetura e treinamento de uma rede neural

A arquitetura de uma rede neural é de vital importância, pois define o tipo de problemas que ela é capaz de avaliar. Cada arquitetura é utilizada para resolver diferentes tipos de problemas, como as arquiteturas de redes neurais convolucionais usadas em problemas de Visão Computacional e as redes neurais recorrentes usadas em problemas de Processamento de

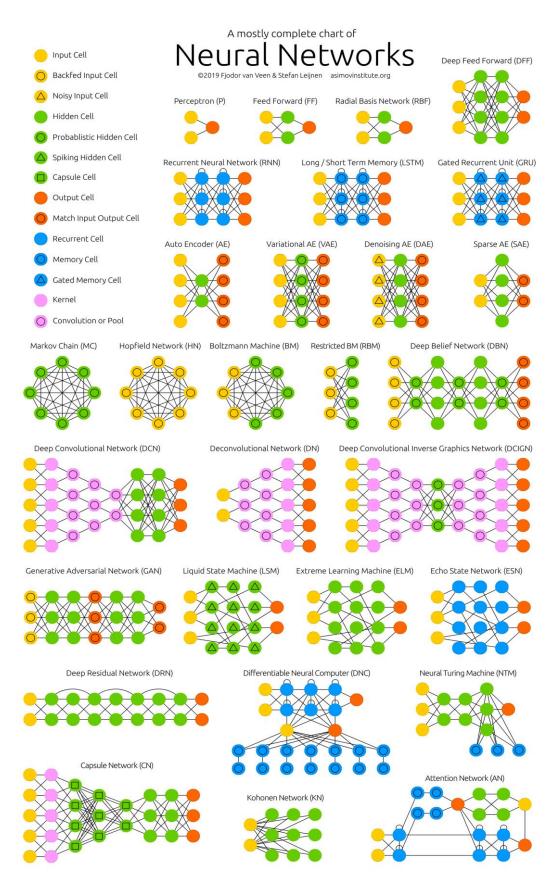
Linguagem Natural (VAN VEEN LEIJNEN, 2019). Na Figura 3 são apresentadas as principais arquiteturas disponíveis.

Embora todas essas arquiteturas sejam de redes neurais artificiais, nem todas são de *deep learning*. O que caracteriza modelos de aprendizagem profunda, como o nome sugere, são redes neurais artificiais com muitas camadas ocultas (ou intermediárias) (DAS e PAUL, 2020). Alguns exemplos de arquiteturas que podem ser encontradas na imagem são *perceptron* (ROSENBLATT, 1958); *FeedFoward* (FF), que é uma rede neural artificial em que as conexões entre os nós não formam um ciclo, e rede neural recorrente (RNN), que é uma classe de redes neurais artificiais em que as conexões entre os nós formam um gráfico direcionado ao longo de uma sequência temporal. Isso permite que ele exiba um comportamento dinâmico e temporal.

Long short-termmemory (LSTM) é uma arquitetura de rede neural recorrente artificial (RNN) usada no campo de aprendizado profundo. Ao contrário das redes neurais feedforward padrão, LSTM tem conexões de feedback. Ela pode não apenas processar pontos de dados únicos (como imagens), mas também sequências inteiras de dados (como fala ou vídeo).

Durante a criação e treinamento de um novo modelo neural a ser aplicado a um determinado problema, procura-se por modelos que sejam capazes de generalizar ao invés de serem precisos. Tal escolha tem como objetivo tornar a rede capaz de atuar com melhor acurácia sobre dados que não foram apresentados à rede no momento do treinamento. Assim como os humanos, ele se torna capaz de detectar, por exemplo, um macaco livre na floresta, mesmo só tendo anteriormente como exemplos macacos presos em um zoológico, ou seja, o sistema é capaz de inferir que as barras que impediam o macaco de sair de seu confinamento não faziam parte do indivíduo e sim do contexto no qual aquele estava inserido (ZEILER; FERGUS, 2014).

Figura 3. Exemplos de rede neurais



Fonte: VAN VEEN; LEIJNEN, 2019.

Para que redes neurais sejam capazes de generalizar, estas devem se treinadas por longos períodos e com o maior número de exemplos possíveis. Devido a tal necessidade, faz-se necessária a utilização de computadores de alto poder de processamento, memória e processamento paralelo utilizando GPUs. Devido aos altos custos e longo período de treinamento de novos modelos neurais, uma técnica que vem se destacando é a técnica de *transfer learning*, em que modelos previamente treinados e de livre acesso são estendidos para serem capazes de realizar a classificação de objetos não apresentados ao modelo no momento de seu treinamento (OLIVEIRA; ROMERO, 2018).

Três tipos de treinamento podem ser aplicados a essa técnica: treinamento total, no qual os pesos do treinamento da rede são considerados como valores iniciais para o novo treinamento; treinamento parcial, no qual somente uma camada convolucional e a camada densa são treinadas novamente, e o treinamento mínimo, no qual apenas a camada densa é treinada novamente.

Apesar de a técnica de *transfer learning* auxiliar na redução dos recursos e do tempo necessários para o treino do modelo, esta não exime a necessidade de computadores de alto poder de processamento, devido à grande complexidade das redes a serem estendidas.

No trabalho aqui proposto, utilizou-se uma rede neural *Inception-ResNet-v4* (SZEGEDY et al., 2016), já treinada e de livre acesso, se aplicou a técnica de *transfer learning*, para que a rede fosse treinada para identificar se uma planta estava ou não sob estresse hídrico, independentemente de sua fase fenológica. Durante a aplicação da técnica de *transfer learning*, os exemplos coletados foram utilizados para seu treinamento. Como resultado da predição realizada pela rede, obtiveram-se sugestões de manejo hídrico localizado na área monitorada quando necessário. Como descrito anteriormente, o modelo não executou ações de correção, sendo o usuário livre para realizar as medidas corretivas ou não, pois essa tomada de decisão pode estar diretamente relacionada a outros critérios, como os econômicos, por exemplo, quanto ao acionamento de um sistema de irrigação.

2.8 Análise de desempenho para sistemas de classificação

Devido às características do método proposto neste trabalho, os métodos estatísticos clássicos de avaliação, como o erro quadrático médio da raiz "RMSE" e o índice de concordância R², não são suficientes para determinar seu desempenho. Assim, buscaram-se métodos que melhor se adequassem à tarefa. Os métodos de avaliação do desempenho de sistema de classificação que vêm sendo largamente utilizados pela comunidade científica são a matriz de confusão, *receiver operating characteristics* (ROC) e *area under the curve* (AUC) (HANLEY; MCNEIL; 1982).

Matrizes de confusão – também conhecidas como matrizes de erro – constituem-se como uma maneira natural de apresentar as estatísticas para esse tipo de sistemas, por meio da tabulação cruzada entre a classificação realizada pelo modelo e a real classificação do exemplo (PRATI; FLACH, 2005). Por meio dessa tabela, é possível coletar estatísticas do modelo com acurácia, sensibilidade e precisão do método avaliado.

A precisão dos dados espaciais foi definida pelo Serviço Geológico dos Estados Unidos (USGS) como: "A proximidade dos resultados de observações, cálculos ou estimativas para os valores verdadeiros ou os valores aceitos como verdadeiros" (USGS, 1990). Mesmo assim, devese levar em conta que a "verdade" tem uma certa dimensão subjetiva (JANSSEN; VAN DER WEL, 1994).

Esta análise pode ser utilizada para uma variedade de aplicações, porém, seus utilizadores devem ser capazes de avaliar se a precisão do mapa se adéqua aos seus objetivos. Portanto, matrizes de confusão tornaram-se amplamente aceitas como método para relatar o erro de dados rasterizados. Diferentes métodos foram desenvolvidos para avaliar essas matrizes de erro, métodos não estatísticos estão incluídos, aqueles com base nos coeficientes de concordância e na distribuição binomial (ARONOFF, 1982). Embora esses métodos forneçam uma ferramenta poderosa para avaliar matrizes de erro, todos eles possuem certas suposições sobre a coleta de dados que as preenchem. Supõe-se ainda que a classificação incorreta de uma determinada área possa ser inequivocamente determinada (GINEVAN, 1979).

A suposição primordial em todo o procedimento de avaliação da precisão é que a matriz de confusão deve ser representativa de toda a área dos dados sendo a amostragem correta fundamental, pois nesta, análises futuras se baseiam na detecção do mapa remotamente (CONGALTON, 1988). Se essa premissa for violada, todos os resultados da avaliação de precisão serão anulados. Portanto, para a avaliação da precisão, não somente a própria matriz de confusão deve ser avaliada, mas também todo o procedimento de coleta de dados.

Uma análise complementar às medidas produzidas pela matriz de confusão é o uso de gráficos, permitindo uma visualização do desempenho do sistema. A análise ROC (do inglês *receiver operating characteristics*) pode ser gerada a partir das informações contidas na matriz de confusão e se baseia na taxa de detecções corretas e na taxa de rotulações errôneas para a classe. Assim, um sistema de classificação é representado na curva ROC por um ponto. A análise ROC foi inicialmente utilizada para fins militares, na detecção da qualidade do sinal em um canal com ruídos de sinais (EGAN, 1975), sendo muito utilizada também na medicina, para determinar a qualidade de um diagnóstico; na psicologia, para avaliar a capacidade de indivíduos de distinguir entre

estímulos e não estímulos (ZHOU et al., 2002; SILVA et al., 2004), e na avaliação de predição de eventos climáticos raros (MYLNE, 2002).

Bradley (1997) e Spackman. (1989) apresentaram a análise ROC como uma ferramenta útil e poderosa para avaliação de modelos de classificação, sendo particularmente útil em domínios nos quais exista uma grande desproporção entre as classes ou quando deve ser considerado o custo para os diferentes erros/acertos de classificação. Esse tipo de análise é também utilizado na construção civil (PRATI; FLACH, 2005) e refinamento de modelos (FLACH; WU, 2005).

Outra característica das curvas ROC é que estas podem ser geradas a partir da simulação por meio da escolha de vários limiares, variando em todo seu aspecto. Esta simulação faz-se útil para avaliar pontos de corte no modelo baseado no custo desejado. Em complemento à análise visual da curva ROC, a análise *area under the curve* (AUC) diz respeito ao desempenho geral do método de classificação e quantifica sua capacidade de classificar corretamente qualquer instância em relação a uma escolha aleatória "Estocástica" (PRATI; FLACH, 2005).

De acordo com Silva et. al (2004), é possível calcular a AUC assumindo que as probabilidades subjacentes de prever resultados negativos ou positivos são gaussianas. A curva ROC terá então uma forma exponencial e pode ser montada diretamente usando uma estimativa iterativa de máxima verossimilhança (ML), fornecendo a diferença de médias e a proporção de variações das distribuições positivas e negativas; ou, se a curva ROC é plotada em papel de dupla probabilidade, uma linha reta pode ser ajustada nos pontos da curva ROC. A inclinação e a interceptação desta linha montada são usadas para obter uma estimativa da AUC.

3 HIPÓTESES

Este trabalho possui duas hipóteses primárias:

- a) Redes neurais convolucionais podem ser treinadas para avaliar imagens termais e inferir se uma planta está sob estresse hídrico;
- b) Redes neurais convolucionais podem substituir métodos agronômicos clássicos, provendo assim uma ferramenta eficaz para monitoramento da água na planta sem exigir infraestrutura complexa.

4 MATERIAL E MÉTODOS

O experimento foi conduzido em casa de vegetação instalada na área experimental do Departamento de Engenharia de Biossistemas (LEB) da Escola Superior de Agricultura "Luiz de Queiroz" (ESALQ/USP), em Piracicaba, no estado de São Paulo, nas seguintes coordenadas geográficas: 22° 42' 39,2" de latitude sul e 47° 37' 44,4" de longitude oeste (LER, 2020), com uma altitude de aproximadamente de 548 m (Figura 4).

A casa de vegetação possui área total de 160 m², pé direito de 3 m, tendo cobertura de filme plástico de polietileno transparente de 150 micras e laterais fechadas com tela tipo "sombrite" com 30% de interceptação. A estrutura é provida de 56 caixas de cimento amianto de 500 L, com área de aproximadamente de 1 m², em quatro faixas espaçadas em dois agrupamentos equidistantes e 50 cm entre caixas (Figura 4).



Figura 4. Área experimental – foto aérea, casa de vegetação e unidades experimentais

Fonte: Google Maps, 2020 e registros fotográficos pelo autor.

4.1 Solo

Para a condução do experimento, foram utilizadas caixas hidrologicamente fechadas de 0,92 m de largura, 1,08 m de comprimento e altura de 0,65 m. No fundo das caixas, foi instalada uma camada de brita com 5 cm de espessura (Figura 5), revestida por uma manta geotêxtil "bidim". Foi instalado um tubo de PVC de 25 mm de diâmetro, perfurado e revestido na parte inferior pela mesma manta e enterrado verticalmente no solo, servindo como tubo de acesso para drenagem dos vasos em casos de excesso de aplicação de água, conforme a Figura 5.

Figura 5. Unidade experimental (a) área das parcelas, (b) vista lateral da parcela com tensiômetros para controle da irrigação.



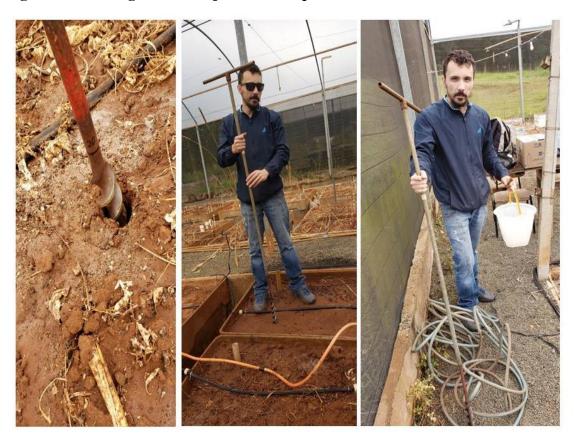


Fonte: Imagens capturadas pelo autor.

Foi utilizado para o preenchimento das caixas um solo que ocorre na região de Piracicaba-SP, classificado como latossolo vermelho amarelo, fase arenosa, série Sertãozinho. Foram tomadas amostras aleatórias compostas das camadas de 0 a 20 m, 20 a 40 m e 40 a 60 m de profundidade dentro das caixas, utilizando o trado de rosca, e enviadas para o Laboratório de Análise de Solos do Departamento de Ciência do Solo (LSO) da ESALQ-USP, obtendo-se os valores apresentados

na Tabela 1. As características químicas foram determinadas mediante estudo em laboratório, as quais foram usadas para o manejo da adubação.

Figura 6. Amostragem de solo para análise química.



Fonte: Acervo pessoal.

Tabela 1. Caracterização química do solo utilizado no experimento

Profundida de (m)	pH Ca Cl ₂	M.O.	Р	S	Fe	Na	K	Ca	Mg	H + Al	SB	СТС	7	V	N		Si
														Total	NH ⁺⁴	NO ⁻³	
	(g (dm-3)			(mg	dm-3)				(mm	olc dm-3)	%		(mg.kg ⁻¹)		
0,00 - 0,20	6	22	27	26	22	28 5	1,4	34	11	18	46,4	64,4	72	1400	14	11	8
0,20 - 0,40																	9
0,40 – 0,60	5,9	23	30	67	10 0	31 5	1,1	31	16	20	48,1	68,1	71	1540	11	39	8

Métodos: M.O – Dicromato/colorimétrico; P, K, Ca e Mg – Resina; S – Ca(H_2PO_4)₂; Fe - DTPA; Na – duplo ácido; H+Al – SMP; N total, NH⁺⁴ e NO⁻³– digestão sulfúrica/Kjeldahl; Si –CaCl₂

Fonte: Elaborada pelo autor.

Para a determinação dos parâmetros físico-hídricos do solo (Tabela 2), foram tomadas amostras indeformadas de solo nas três camadas antes descritas; estas foram enviadas para o Laboratório de Física do Solo do Departamento de Engenharia de Biossistemas (LEB) da ESALQ-USP. As características físico-químicas foram utilizadas para manejo da irrigação.

Tabela 2. Caracterização físico-hídrica do solo utilizado no experimento

Profundidade	Capacidade de campo (θ _{cc})	Ponto de murcha permanente (θ _{pmp})	Porosidade total (%)	Capacidade de água disponível	Densidade do solo	Densidade das partículas		Fraçõe iulomé	
							Areia	Silte	Argila
(cm)		(cm^3cm^{-3})		(mm)	(g c	m^{-3})		%	
0 – 20	0,23	0,11	44,44	24,22	1,5	2,7	75,1	7,8	17,1
20 - 40	0,23	0,1	44,44	25,62	1,5	2,7	74,5	8,0	17,5
40 - 60	0,24	0,13	34,62	21,76	1,7	2,6	74,4	8,6	17

Métodos de determinação segundo EMBRAPA (1997). θcc capacidade de campo, θpmp ponto de murcha permanente, CAD capacidade de água disponível e Frações granulométricas do solo.

Fonte: Elaborada pelo autor.

4.2 Manejo da irrigação

O sistema de irrigação adotado foi por gotejamento, utilizando tubo gotejador com emissor autocompensante, anti-sifão e antidrenante. Para controlar individualmente cada parcela experimental, foram instaladas duas linhas de gotejamento com dois gotejadores espaçados em 0,20 m e com vazão de 2 L h⁻¹ em cada gotejador. A avaliação da uniformidade de vazão dos gotejadores foi realizada em área experimental por meio de testes de uniformidade, considerando 30 gotejadores, utilizando os coeficientes de uniformidade CUC e CUD, obtendo-se os valores de 91,4% e 85,1% respectivamente (Figura 7).

Figura 7. Teste de uniformidade do sistema de irrigação





Fonte: Acervo pessoal.

O manejo da irrigação foi realizado por meio do monitoramento da tensão da água no solo, utilizando baterias de tensiômetros de punção em três profundidades (0,15; 0,25 e 0,35 m), com seis baterias de tensiômetros (Figura 8). Após as leituras de tensão, os valores coletados foram transformados em potencial matricial (ψ_m) (equação 1) da água no solo e, em seguida, a estimativa da umidade foi realizada por meio do modelo proposto por van Genuchten (1980) (equação 2), cujos parâmetros estão presentes na Tabela 3.

Figura 8. Bateria de três tensiômetros



Fonte: Registros fotográficos pelo autor.

$$\psi_{m} = L_{t} - h_{c} \tag{1}$$

Em que:

ψ_m - potencial matricial da água no solo (kPa);

L_t - leitura do tensiômetro ou tensão da água no solo (kPa);

h_c - pressão equivalente à altura da coluna d'água no tensiômetro (kPa);

$$\theta(\Psi_{\rm m}) = \theta_{\rm r} + \frac{(\theta_{\rm s} - \theta_{\rm r})}{[1 + (\alpha |\Psi_{\rm m}|)^{\rm n}]^{\rm m}}$$
 (2)

Em que:

 θ (ψ_m) - umidade volumétrica em função do potencial mátrico, em m³ m⁻³;

 θ_r - umidade volumétrica residual do solo, em m³ m⁻³;

 θ_s - umidade volumétrica do solo saturado, em m³ m⁻³;

m e n – parâmetros numéricos de ajuste da equação, adimensionais;

α - parâmetro com dimensão igual ao inverso da tensão, em kPa⁻¹;

 ψ_m - potencial mátrico, em kPa.

Tabela 3. Valores dos componentes e parâmetros da equação de van Genuchten (1980) para o latossolo vermelho, fase arenosa, série Sertãozinho, usado no experimento

Profundidade	θ_{s}	$\theta_{ m r}$	A	M	N
(cm)	$(cm^3 cm^{-3})$	$(cm^3 cm^{-3})$	(kPa ⁻¹)		
0-20	0,421	0,098	1,3464	0,18	2,718
20-40	0,412	0,085	1,5708	0,165	2,503
40-60	0,374	0,122	1,1291	0,275	1,562

Profundidade é a camada do solo sendo analisada, θr é a umidade residual volumétrica do solo em m³ m⁻³; θs umidade volumétrica do solo saturado, e α , m, n são os parâmetros numéricos de ajuste da equação

Fonte: Elaborada pelo autor.

As lâminas de irrigação (L_i) diárias destinadas a repor a umidade do solo até a capacidade de campo (θcc) foram determinas em cada tratamento com os dados de umidade estimados (Tabela 3), resultando no somatório das lâminas exigidas em cada camada de solo (0,00-0,20 m, 0,20-0,40 m e 0,40-0,60 m) calculadas pela equação 3. Após obtida a lâmina de irrigação necessária para cada tratamento, foi calculado o tempo de irrigação empregando-se a Equação 4.

$$L_i = \sum_{1=20}^{60} (\theta_{cci} - \theta_i) Z_i$$
 (3)

Em que:

L_i – lâmina necessária para elevar a umidade do solo até capacidade de campo, mm;

 θ_{cci} - umidade volumétrica na capacidade de campo para a camada i, cm³ cm⁻³;

 θ_i - umidade volumétrica atual estimada pela equação 2 para a camada i, cm³ cm⁻³;

Zi –espessura da camada i, mm.

$$T_i = \frac{60 L_i A}{Q E_a} \tag{4}$$

Em que:

T_i – tempo de irrigação, minutos;

L_i – lâmina necessária para elevar a umidade do solo até capacidade de campo, mm;

A – área da superfície de solo da parcela experimental (considerando-se como 1 m²);

Q - vazão, L h-1; e

Ea – eficiência de aplicação de água para cada tratamento de 90%.

Na Figura 9, pode-se visualizar uma representação do ambiente experimental, com todas as 24 parcelas experimentais, cada uma com duas linhas de gotejamento. O painel de controle de irrigação conectava-se a cada uma das parcelas e à motobomba responsável pela pressurização do sistema. Utilizou-se o software Microsoft Excel®, para o cálculo automatizado das lâminas de reposição, bem como para realizar o monitoramento da variação do potencial mátrico.

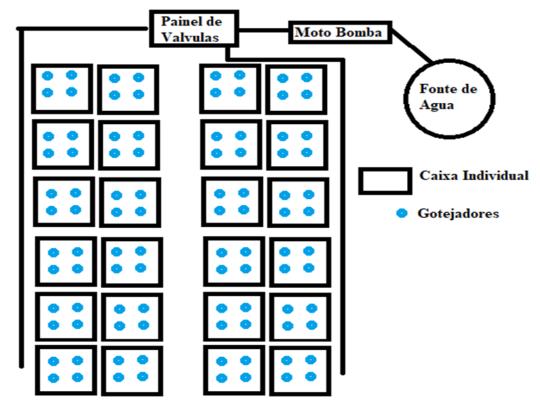


Figura 9. Representação esquemática do sistema de irrigação

Fonte: Elaborada pelo autor.

Para estabelecer o controle das lâminas a serem aplicadas em cada parcela, foi projetado um painel com válvulas individuais (Figura 10 a). O controle do tempo de abertura das válvulas foi realizado de forma manual. A reposição hídrica foi realizada diariamente, tendo como objetivo manter as plantas com o fornecimento de água definido para o estudo, a fim de se ter exemplos que representassem todo o ciclo da cultura. A estrutura, arquitetura e metodologia referente ao manejo da irrigação descrita neste item, foram as mesmas utilizadas em ambos os ensaios realizados com as distintas culturas estudadas nesta pesquisa.

Figura 10. Manejo da irrigação – (a) quadro de válvulas para controle das lâminas, (b) parcela com gotejadores, (c) parcela com tensiômetros para monitoramento do solo, (d) rotulação do registro para controle da irrigação, (e) motobomba e medidor de pressão e (f) caixas para fornecimento de água e fertirrigação



Fonte: Registros fotográficos pelo autor.

4.3 Adubação

A correção química do solo foi realizada por meio de um sistema de fertirrigação, de acordo com as recomendações do Boletim 100 do Instituto Agronômico de Campinas, para a cultura da soja no Brasil (TEIXEIRA et al., 2015). O tratamento foi aplicado apenas para o ensaio conduzido com a cultura da soja, para o ensaio com cana-de-açúcar não foi realizado adubação.

Os macronutrientes foram aplicados em linhas do fertilizante (Figura 11), para que possibilitasse a sua incorporação gradual. As parcelas foram irrigadas com o objetivo de evitar a salinização do solo.

Figura 11. Elementos do tratamento de adubação para a cultura da soja – (a) fertilizante fracionado, (b) aplicação do fertilizante em linha





Fonte: Registros fotográficos pelo autor.

4.4 Aplicação de defensivos agrícolas

Devido às características da cultura da soja, durante todo o experimento, conduziu-se o controle fitossanitário, com intuito de identificar possíveis pragas e evitar o comprometimento do ensaio. Foi constatada, inicialmente, a presença de cochonilhas, controladas com a aplicação de defensivo agrícola Nomolt 150 (Basf).

Também foi constatada a presença de ácaros, eliminados com a aplicação de Actara (fungicida sistêmico) junto com a água de irrigação (0,30 g do produto em 100 L de água na caixa). Para a cana-de-açúcar não houve a necessidade de aplicação de defensivos agrícolas.

4.5 Tratamento e delineamento experimental

Esta seção apresenta dois ensaios realizados, um que foi conduzido com a cultura da canade-açúcar e outro com a cultura da soja. O delineamento experimental adotado foi em blocos casualizados - DBC, com quatro blocos e lâminas de irrigação aplicadas a partir do 30º dia após o plantio. A realização de experimentos com mais de uma espécie de planta teve como objetivo avaliar

o método aqui proposto, com relação à sua adequabilidade para mais de uma espécie de planta, bem como seu comportamento quando utilizado com espécies de plantas distintas e diferentes níveis de reposição hídrico de forma simultânea.

4.5.1 Cana-de-açúcar

O experimento com a cana-de-açúcar teve início no dia 11/08/2019 e foi conduzido por um período de 120 dias. Nos primeiros 30 dias de experimento, todas as parcelas foram irrigadas ao nível de 100% da 0cc do solo, tendo como objetivo uniformizar as parcelas e a formação de massa foliar. Após o período de 30 dias, deu-se início ao regime de reposição parcial de água, aplicando-se as lâminas de irrigação pré-definidas, com frequência diária.

O delineamento experimental adotado foi em blocos casualizados - DBC, com quatro blocos e três lâminas de irrigação aplicadas a partir do 30° dia após o plantio. A unidade experimental foi representada por uma caixa com cinco plantas, ou seja, foram utilizadas 120 plantas (Figura 12).

Figura 12. Área experimental – (a) exemplo de uma parcela com seu tratamento, (b, c) visão geral da área experimental







Fonte: Registros fotográficos pelo autor.

As lâminas de irrigação aplicadas foram: L100% – lâmina de irrigação para repor 100% da demanda hídrica da cultura, L50% – para suprir 50% da demanda da cultura e L25% – para suprir 25% da demanda da cultura. O nível de referência (L100%) manteve a umidade do solo próxima à capacidade de campo (θcc) ao longo de todo experimento, sendo este correspondente à lâmina para repor 100% da CAD, com base na umidade atual do solo. Os demais níveis de lâminas (L50%, L25%) foram variações proporcionais na fração de reposição tomando como referência o tratamento L100%. Após início da aplicação das lâminas, a imposição desses tratamentos foi mantida até o final do experimento, com o objetivo de obter exemplos para todo o ciclo. Na Figura 13 pode-se observar a distribuição das parcelas experimentais após a casualização.

L100
L50
L25

Figura 13. Croqui experimental com a distribuição das parcelas para cana-de-açúcar

Fonte: Elaborada pelo autor.

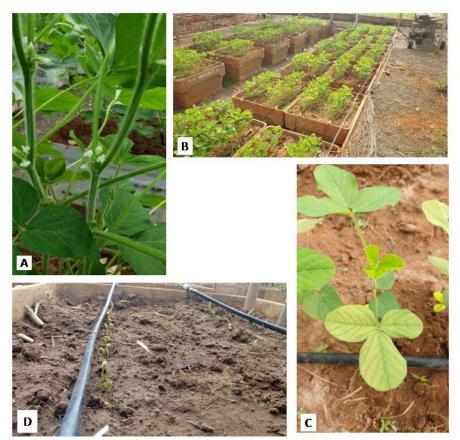
4.5.2 Soja

O experimento com a cultura da soja teve início no dia 20/12/2019 e foi conduzido por um período de 92 dias. Nos primeiros 36 dias de experimento – período definido como a data de formação de flores – todas as parcelas foram irrigadas ao nível de 100% θ cc , tendo como objetivo

uniformizar as parcelas e a formação de massa foliar. Após o período de 36 dias, deu-se início ao regime de reposição parcial de água, aplicando-se as lâminas de irrigação pré-definidas.

O delineamento experimental adotado foi realizado em blocos casualizados – DBC, este foi formado por quatro blocos e quatro níveis de reposição hídrica aplicadas a partir do 36° dia após o plantio. A unidade experimental foi representada por uma caixa com 12 plantas, ou seja, foram utilizadas 288 plantas.

Figura 14. Ensaio com soja, a) soja em floração, b) plantio em área experimental, c) Soja em fase vegetativa e d) sistema de irrigação utilizado.



Fonte: Registros fotográficos pelo autor.

As lâminas de irrigação aplicadas foram: L100% – lâmina de irrigação para atingir 100% θcc , L70 – lâmina de irrigação para atingir 70% θcc , L40% – lâmina de irrigação para atingir 40% θcc e L130% – lâmina de irrigação para atingir 130% da CAD. O nível de referência (L100%) manteve a umidade do solo próxima à capacidade de campo (θcc) ao longo de todo experimento, sendo este correspondente à reposição para 100% θcc . Os demais níveis de lâminas (L70%, L40%, L130%) foram variações na fração aplicada tomando como referência o tratamento L100%. O tratamento L130% teve como objetivo avaliar se o método aqui proposto é capaz de excesso de

água. Após início da aplicação das lâminas, a imposição desses tratamentos foi mantida até o final do experimento, com o objetivo de obter exemplos para todo o ciclo.

Figura 15 apresenta a distribuição das parcelas experimentais após a casualização.

L130
L100
L70
L40

Figura 15. Croqui do ensaio com a cultura da soja

Fonte: Elaborada pelo autor.

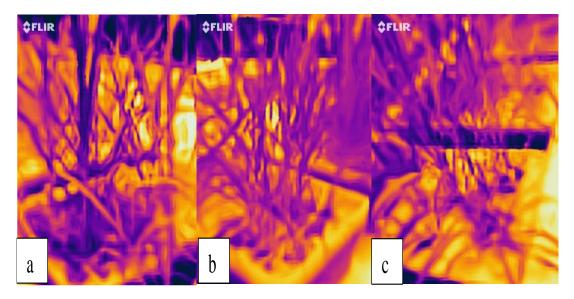
4.6 Criação da base de dados

Para criação da base de dados, após cinco dias em que as parcelas estavam sob regimes hídricos distintos, iniciou-se a coleta das imagens térmicas, sendo coletadas cinco imagens em cada dia em posições distintas para cada uma das parcelas. Junto com as imagens, obteve-se a rotulação de acordo com o regime hídrico aplicado. Exemplos de imagens que compõem a base de dados são apresentados na

Figura 16, referente ao ensaio com cana-de-açúcar. A base de dados utilizada para o treinamento foi composta por 4.050 imagens para cultura da cana-de-açúcar, sendo 1.350 de cada

uma das lâminas aplicadas. E 1008 imagens para a cultura da soja, sendo 252 para cada uma das classes.

Figura 16. Exemplos de imagens termais coletadas nas lâminas de irrigação de (a) 100%, (b) 50% e (c) 25% da CAD para a cultura da cana-de-açúcar



Fonte: Imagens capturadas pelo autor com FlirOne®.

A captura das imagens em ambas as culturas estudadas, foram realizadas em diferentes horários do dia no período entre as 9h e 14h, utilizando uma câmera térmica da marca Flir® modelo *FlirOne* (

Figura 17), que pode ser utilizada em celulares. A escolha desta câmera teve como principal motivo seu baixo custo, bem como o fato de disponibilizar as imagens em um dispositivo capaz de executar o modelo futuramente para predições, disponibilizando uma ferramenta acessível ao pequeno e médio produtor rural. A câmera possui faixa dinâmica de cena entre - 20 °C e 120 °C, sensibilidade térmica de 100 mK, imagem e vídeo salvos como 640X480, precisão de ±3% °C ou ±5% °C e Taxa de Quadros 8,7 Hz.

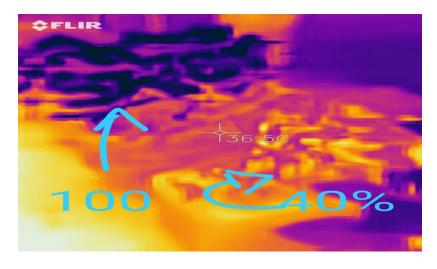
Figura 17. Câmara termal *FlirOne*, utilizada para a criação do banco de dados dos experimentos com cana-de-açúcar e soja



Fonte: Registro fotográfico pelo autor.

Um exemplo da variação térmica que pode ser identificada em uma imagem termal é apresentado na Figura 18 referente ao ensaio com soja, capturada contemplando duas parcelas, uma de L40% e outra de L100%. Como pode ser observado, a planta sob regime hídrico de 100% apresentou coloração azulada, indicando estar abaixo da temperatura do ambiente, enquanto a planta com o regime hídrico de L40% apresentou uma coloração avermelhada, demonstrando estar com temperatura igual ou superior ao ambiente. A figura 19 apresenta o Software FlirTools® utilizado durante a avaliação manual por especialista.

Figura 18. Exemplo de imagem termal obtida com amostras que receberam os tratamentos de 100% e 40% da CAD para a cultura da soja



Fonte: Imagem capturada pelo autor com FlirOne®.

BIBITOTECS

Relations

Modelos

Col Intello

Porture received

Procure received

Relations

Colleges

Colleges

Relations

Figura 19. Software FlirTools ®, utilizado para a análise manual das imagens

Fonte: Captura de tela pelo autor.

4.7 Monitoramento climático

Durante todo o experimento, as condições climáticas da casa de vegetação foram monitoradas com o único objetivo de acompanhamento. A radiação solar global (Qg) foi registrada por um piranômetro de fotodiodo de silício (LI200X - Campbell Sci.) e temperatura do ar (°C) e a umidade relativa (%), por um sensor Vaissala (HMP45C - Campbell Sci.), instalados no interior da casa de vegetação com intervalo de coleta de 15 minutos (valores médios).

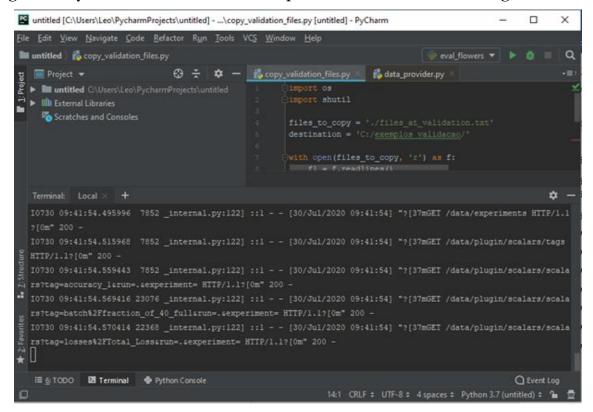
4.8 Ambiente computacional e treinamento da rede neural

4.8.1 Arquitetura computacional

Como descrito anteriormente, o método computacional avaliado necessita de grande poder de processamento, motivo pelo qual se fez necessária sua construção visando a alta disponibilidade de memória RAM, poder de processamento, bem como a disponibilidade de placas gráficas. Assim, o ambiente computacional utilizado para este trabalho foi composto por uma placa GeForce® RTX 2080 Ti com 11G de memória DDR6, 4.352 núcleos CUDA, frequência de 1.350 MHz, processador Intel® Core™ i9-900 CPU @ 3,600 GHz, Memória RAM 32 GB DDR6. O software livre Tensorflow® e suas sub-bibliotecas foram utilizados por conter abstrações de modelos, arquitetura de redes neurais e, ainda, fornece ferramentas para a transformação das bases de dados a serem utilizadas. A linguagem de programação para a criação do código utilizado durante

o treinamento da rede foi a linguagem Python®. O código implementado para realizar o treinamento foi dividido em três etapas: preparação dos exemplos, treinamento do modelo utilizando *transfer learning* e validação do treinamento. Para facilitar o processo de desenvolvimento, o ambiente de programação PyCharm® foi utilizado, por disponibilizar interface gráfica, bem como outras ferramentas que auxiliam no processo de desenvolvimento (Figura 20).

Figura 20. PyCharm - ferramenta utilizada para o desenvolvimento do código



Fonte: Captura de tela pelo autor.

Na técnica de *transfer learning*, redes previamente treinadas são estendidas para serem capazes de reconhecer novas classes, reduzindo a quantidade de recurso computacional e tempo para seu treinamento. Foi utilizada a rede *Inception-Resnet-V4* (SZEGEDY et al., 2016), utilizando os pesos de seu último treinamento (Figura 21). Este é composto por 185 camadas convolucionais e 50 camadas densas.

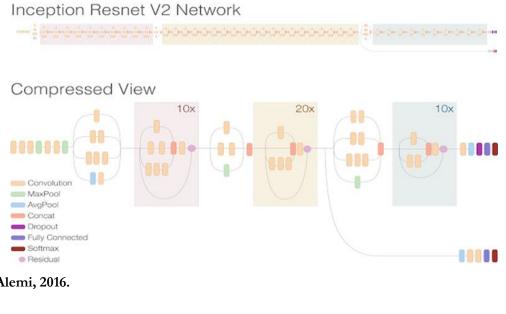
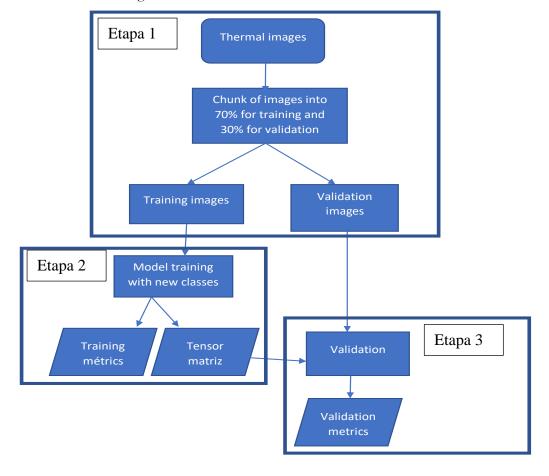


Figura 21. Representação esquemática da arquitetura da rede Inception-Resnet-v2

Fonte: Alemi, 2016.

4.8.2 Treinamento

O Fluxograma da Figura a seguir representa as etapas utilizadas durante o treinamento, representando o a metodologia utilizadas.



A primeira parte implementada foi a alocação dos conjuntos de testes e validação a partir das imagens coletadas durante o experimento. Para tanto, as imagens termais foram convertidas nas dimensões de 320 X 240 pixels com três canais de cores RGB e vetorizadas. Em seguida, foram subdivididas em 70% para treinamento e 30% para validação e convertidas do formato JPG para o formato tfrecord.

Na segunda etapa, deu-se início ao treinamento da rede neural. Durante essa fase, o modelo foi importado e carregado com os pesos de seu último treinamento conforme apresentado em Szegedy et al. (2016). Este, por sua vez, carrega os pesos de todas as 50 camadas densas e 185 blocos convolucionais. Como o modelo original foi treinado para classificar 1.000 classes, os pesos da camada densa superior foram descartados e o gráfico da rede foi adaptado para acomodar o número de classes deste trabalho, que são: a) três para a cana-de-açúcar – 25%, 50% e 100% da lâmina para atingir a θcc – e quatro para a soja – 40%, 70%, 100% e 130% da lâmina para atingir a θcc. Em seguida, as imagens foram apresentadas à rede em batch de 10 imagens.

A função Softmax (Equação 5) com entropia cruzada foi utilizada como função de custo. Esta recebe o tensor da camada superior como parâmetro de entrada e aplica internamente a função Softmax antes de calcular a entropia cruzada. Também foi utilizada a Otimização de Adam, um algoritmo para atualizar a taxa de aprendizado durante o treinamento da rede neural. Este é considerado o mais adequado para a grande maioria das redes convolucionais e está disponível entre as bibliotecas do Tensorflow (KINGMA; BA, 2014).

A taxa de aprendizado com decaimento exponencial foi aplicada, sendo o maior valor possível no início do treinamento. Os valores testados durante o desenvolvimento do trabalho são apresentados na Tabela 4.

$$softmax = \frac{exp\left(\sum_{j} w_{kj} x_{j}\right)}{\sum_{l} exp\left(\sum_{j} w_{lj} x_{j}\right)}$$
 (5)

Em que:

w_{kj} é o peso da conexão k a j;

W_{lj} é o peso da conexão k a l;

x_i o valor de ativação do neurônio k.

Na terceira e última etapa, o modelo já treinado foi utilizado para a predição das classes de estresse hídrico das 30% imagens restantes, que foram separadas para validação e teste de aderência. Essa etapa teve o objetivo de avaliar a acurácia do modelo quando aplicado às imagens não utilizadas durante o treinamento.

Para a obtenção do melhor treinamento possível da rede, diversas combinações de taxa de aprendizado e número de épocas foram experimentadas. A Tabela 4 apresenta os parâmetros que foram utilizados para cada um dos treinamentos realizados, bem como a acurácia alcançada.

Tabela 4. Treinamentos realizados – taxas de aprendizado experimentadas; número de épocas em que o modelo foi treinado; acurácia para o treinamento

Taxa de aprendizado	Número de épocas*	Acurácia
0,00001	1000	63%
0,0001	1000	91%
0,001	1000	67%
0,001	500	63%

Fonte: Elaborada pelo autor.

Para cada uma das combinações apresentadas, foram realizados o treinamento do modelo e a avaliação do treinamento utilizando o software TensorBoard®, que se destina à análise das informações coletadas durante o treinamento, como taxa de aprendizado, acurácia por época, acurácia global, loss, entre outras. Entre as informações disponibilizadas pelo TensorBoard está a visualização dos tratamentos aplicados pelo modelo às imagens, como a área que representa a imagem sendo avaliada pelo modelo e sua demarcação através de um *box plot* (Figura 22). Diferentes números de batch foram experimentados para a execução deste trabalho; o treinamento com 10 exemplos demostrou-se o mais adequado para o ambiente utilizado. Em média, cada treinamento foi executado por 12 horas.

As informações disponibilizadas nessa ferramenta foram utilizadas no ajuste do modelo, pois possibilitaram uma análise do seu comportamento e de fatores que estavam influenciando o treinamento da rede. Uma informação que pode ser extraída dessas ferramentas é a influência de exemplos coletados em dias com temperatura ambiente igual ou inferior as 25°C. Como descrito anteriormente, quando a temperatura ambiente é baixa, a imagem termal não provê informação válida devido à baixa variabilidade de temperatura do dossel causada pela redução da evapotranspiração.

^{*}cada época representa o modelo ter percorrido todos os exemplos de teste

\$FLIR
\$FLIR

Figura 22. Exemplo de área considerada pela rede na avaliação, obtidas no ensaio com cana-de-açúcar

Fonte: Imagens capturadas pelo autor com FlirOne®.

Uma ferramenta disponibilizada pelo TensorBoard® é o gráfico da rede, que demonstra de forma gráfica a rede que foi utilizada, bem como seu comportamento durante o treinamento. Este foi utilizado para compreender o funcionamento da rede e implementar o código para este trabalho. A Figura 23 apresenta o gráfico da rede utilizada neste trabalho.

De início foi realizado o treinamento com as imagens da cana-de-açúcar, definindo os melhores parâmetros para seu treinamento (taxa de aprendizado e número de épocas, conforme apresentado na Tabela 4). Posteriormente, o modelo foi novamente treinado com as imagens da cultura da soja, esse treinamento teve como objetivo avaliar se o método é capaz de realizar a mesma tarefa em culturas agrícolas com arquitetura e características diferentes.

Foi realizado também um treinamento com ambos os conjuntos de imagens da cana-deaçúcar e soja, esse treinamento teve como objetivo avaliar a possibilidade de se obter um modelo neural consolidado para sua posterior distribuição e utilização simplificada pelo usuário final.

OneHotEnco... batch case global step betal_power parallel_read beta2_power

Figura 23. Gráfico da rede gerado no TensorBoard®

Fonte: Elaborado pelo autor.

4.9 Avaliação manual por especialista para a cultura da cana-de-açúcar

Com o objetivo de comparar as avaliações realizadas pelo modelo após seu treinamento com a técnica de *trasnfer learning*, foi realizada a avaliação, por um especialista, do conjunto composto pelos 30% das imagens separadas para validação da rede neural, calculando o valor de CWSI e rotulando em uma das classes – 25%, 50% ou 100% da lâmina para atingir a CAD – para todas as 1.008 imagens do conjunto.

A análise das imagens foi realizada utilizando o software *Flir Tools*®, disponibilizado pelo fabricante da câmera termal utilizada para a captura dos exemplos. O software possibilita visualizar a temperatura em diversas áreas da imagem, visualizar a imagem sem dados termais e aplicar diferentes filtros, como o de tons de cinza, entre outras ferramentas.

A utilização do software foi necessária para observar os valores das temperaturas das áreas de interesse, de acordo com metodologia para cálculo do índice de estresse hídrico da cultura (CWSI) conforme proposto por Idso et al. (1981) e Jackson et al. (1981). Com os dados de temperatura obtidos em cada exemplo, foi possível determinar o CWSI como apresentado na Equação (6):

$$CWSI = \frac{(T_c - T_{wet})}{(T_{dry} - T_{wet})}$$
(6)

Em que:

Cwsi: Índice de estresse hídrico da cultura decimal;

Twee: Temperatura da folha sem estresse hídrico °C;

T_{dry}: Temperatura da folha em estresse hídrico °C;

T_c: Temperatura da folha representando o dossel °C.

Pelo fato da rede se destinar à classificação de imagens, buscou-se uma forma de transformar os valores de CWSI calculado em cada uma das imagens em classes que representam o status hídrico baseado na disponibilidade de água para a planta e no desenvolvimento vegetal. Diversos autores demonstraram a correlação entre o CWSI com os indicadores fisiológicos da planta pela análise de regressão mínima quadrada parcial (MANGUS et al., 2016; ELSAYED et al., 2017; MASSERONI et al., 2017; APOLO-APOLO et al., 2020). Assim, considera-se que, na Equação 6, o valor mais baixo obtido é 0, o qual representa o equilíbrio hídrico e a melhor condição para a planta. Já o máximo valor esperado é 1, representando a condição mais crítica.

Partindo dessa premissa, realizou-se a divisão desse intervalo entre zero e um, de forma a atribuir rótulos a cada intervalo, conforme metodologia de Camargo e Hubbard (1999) e proposta por Ciiagro (2020), como apresentado na Tabela 5. Como foram aplicados três níveis de reposição hídrico, realizou-se então uma correlação (Tabela 6) para cada uma das lâminas com as classes apresentadas na Tabela 5.

Tabela 5. Classes de CWSI

Condições de estresse hídrico	Classe de desenvolvimento vegetal	Lâmina referente à CAD
0 = CWSI < 0.2	Ótimas	100%
$0.2 \le CWSI < 0.3$	Favoráveis	100%
$0.3 \le CWSI < 0.4$	Adequadas	50%
$0.4 \le CWSI < 0.6$	Razoáveis	25%
$0.6 \le CWSI < 0.8$	Desfavoráveis	25%
$0.8 \le CWSI \le 1.0$	Críticas	<25%

Fonte: Elaborada pelo autor.

Tabela 6. Classes associadas às lâminas aplicadas nesta pesquisa

Condições de estresse	Classe de desenvolvimento	Lâmina referente à CAD		
hídrico	vegetal	Laithia felefelle a CAD		
$0 \le CWSI < 0.3$	Ótimas/Favoráveis	100%		
$0.3 \le CWSI \le 0.4$	Adequadas	50%		
CWSI > 0.4	Razoáveis/Desfavoráveis	25%		

Fonte: Elaborada pelo autor.

4.10 Comparação entre métodos

Devido à característica do problema apresentado se tratar de uma classificação, os métodos estatísticos clássicos para análise do desempenho de modelos, como o índice de concordância R² e o RMSE, não são os mais adequados para comparar o desempenho entre o método manual e a utilização da rede neural *Inception-Renet-v2*, sendo o limitante para sua execução a incerteza do erro cometido durante cada imagem de forma manual. Assim, buscaram-se métodos estatísticos que pudessem ser utilizados para avaliar o desempenho de redes profundas e aplicá-los à rede após o treinamento com *transfer learning* e a avaliação realizada por um especialista. Métodos que se adéquam melhor à avaliação de métodos classificadores são a matriz de confusão

(sensibilidade, precisão e acurácia); a análise gráfica receiver operating characteristics (ROC) e a area under the curve (AUC) (GIRALDO-GONZÁLEZ et al., 2020).

A matriz de confusão apresenta as frequências de classificação para cada classe do modelo, sendo uma forma de representação da qualidade obtida de uma classificação digital da imagem (CONGALTON, 1991). Refere-se a uma matriz quadrada que expressa a relação do número de unidades de amostra atribuída a uma categoria particular de duas classificações. Nessa matriz, as linhas representam os dados de referência (valor real) e as colunas representam a classificação obtida com algum método de classificação. Em uma matriz de confusão, a frequência observada na diagonal (nii) representa os elementos classificados corretamente. A coluna marginal (ni+) representa o total de elementos classificados para uma categoria i. A linha marginal (n+i) representa o total de elementos de referência amostrados para uma categoria i (Tabela 7).

Congalton (1991) afirma que, se a matriz for mal construída, toda a análise é insignificante. Portanto, os seguintes fatores devem ser considerados para a construção de uma matriz: padrão, unidade e número de amostras. Esses fatores fornecem informações essenciais para a avaliação da matriz de confusão.

Tabela 7. Arquitetura da matriz de confusão

	Preditos						
		Verdadeiro	Falso	Sensibilidade	Precisão	Acurácia	
Rótulos	Verdadeiro	VV	FV	Eq.11	Eq.10	Eq.7	
	Falso	FF	VF	-	-	-	

Fonte: Elaborada pelo autor.

A partir da matriz de confusão, pode-se gerar indicadores da performance do modelo avaliado como a acurácia, precisão e sensibilidade ("recall"). Acurácia diz quanto o modelo acertou das previsões possíveis, sendo esta a razão entre o somatório das previsões corretas (verdadeiros positivos com verdadeiros negativos) e o somatório das previsões, conforme Equação (7).

$$Acurácia = \frac{VV + VF}{VV + VF + FV + FF} = \frac{Predições corretas}{Todas as predições}$$
(7)

Outros dois indicadores que auxiliam na avaliação do modelo referem-se à precisão e à sensibilidade. De acordo com Google Developers (2019), precisão (Equação 10) refere-se à proporção de identificações positivas realmente corretas e sensibilidade (Equação 11) refere-se à proporção de positivos reais identificada corretamente.

$$Precisão = \frac{VV}{VV + FV}$$
 (10)

Sensibilidade =
$$\frac{VV}{VV + FF}$$
 (11)

Com os valores de precisão e sensibilidade, é possível calcular o f-score do modelo (Equação 12), sendo este uma média harmônica que representa o balanço entre a precisão e a sensibilidade do modelo (GOOGLE DEVELOPERS, 2019).

$$f - score = 2 x \frac{precisão * sensibilidade}{precisão + sensibilidade}$$
 (12)

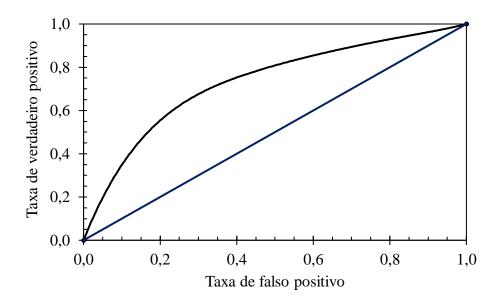
A análise ROC é um método gráfico para avaliação, organização e seleção de sistemas de predição e/ou diagnóstico. Foi originalmente utilizada em detecção de sinais, para avaliar a qualidade de transmissão de um sinal em um canal com ruído (EGAN, 1975), sendo também utilizada na análise climatológica para avaliar a qualidade da predição de eventos raros (MYLNE, 2002), e na economia para análise de renda (GASTWIRTH, 1971).

O Gráfico 1 é obtido a partir da plotagem para uma determinada classe do número de classificações corretas (sensibilidade) no eixo das abscissas, e no eixo das ordenadas o número de falsos verdadeiros (NFV) (Equação 13).

$$NFV = \frac{FF}{FF + VF} \tag{13}$$

Alguns pontos importantes no Gráfico 1 são: o ponto (0,0) representa a estratégia de nunca classificar um exemplo como positivo. Modelos correspondentes a este ponto não produzem nenhuma classificação errônea, mas também não são capazes de produzir uma classificação correta. Um modelo que implemente a estratégia oposta – de sempre classificar um exemplo como sendo da classe – é representado pelo ponto (1,1), porém representará todos os exemplos como pertencente a classe, produzindo um número alto de falsas classificações.

Gráfico 1. Gráfico ROC



Nota: A linha (0,0) a (1,1) representa um modelo com mesma probabilidade de verdadeiros e falso verdadeiros Fonte: Elaborado pelo autor.

O ponto (0,1) representa o modelo perfeito, em que todas as classes são identificadas corretamente, e o ponto (1,0) refere-se ao modelo que sempre faz predições erradas. Com base nesses critérios, modelos próximos ao canto inferior esquerdo do gráfico podem ser considerados "conservativos", pois fazem uma classificação mediante grande certeza, produzindo baixo número de erros e acertos nas classificações. Já modelos próximos ao canto superior direito podem ser considerados "libertos", possuem grande taxa de acerto e erros. Dessa forma, a diagonal ascendente (0,0) a (1,1) representa um modelo estocástico em que cada ponto pode ser representado por (p, per), onde p é a probabilidade da classe e per = 1 – p. Assim, modelos pertencentes ao triângulo superior esquerdo a esta diagonal desempenham melhor que o aleatório, e modelos pertencentes ao triângulo inferior direito, pior que o aleatório (PRATI et al., 2008).

5 RESULTADOS E DISCUSSÃO

Durante a condução deste trabalho, foram realizados os ensaios com duas culturas: a da cana-de-açúcar e a da soja. Para o ensaio realizado com a cana-de-açúcar, foi conduzida a análise do déficit hídrico pelo modelo proposto, bem como de forma manual por especialista, com o objetivo de comparar a proposta com o método manual. O ensaio realizado com soja teve como objetivo avaliar a capacidade do modelo de realizar a mesma tarefa com uma cultura diferente e foi conduzida apenas com o modelo aqui proposto.

5.1 Cultura da cana-de-açúcar

5.1.1 Avaliação por especialista

Os rótulos das imagens eram previamente conhecidos devido ao regime hídrico rigorosamente controlado durante todo o experimento. Após a avaliação das imagens e sua classificação por um especialista, foram contabilizados os números de acertos e de erros na rotulação das imagens. A contabilização foi realizada para cada uma das classes existentes no experimento, bem como para todas as classes em conjunto. Evidenciou-se que o especialista não foi capaz de identificar 34% das imagens de plantas que receberam a lâmina de 25% para atingir a CAD, 38% para as plantas que receberam 50% e 22% das imagens que receberam a lâmina de 100%, obtendo, assim, uma acurácia global de 68% (Gráfico 2).

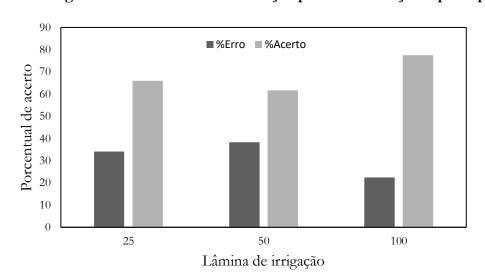


Gráfico 2. Porcentagem de acertos relativa à avaliação para cana-de-açúcar por especialista

Fonte: Elaborado pelo autor.

Pôde-se observar, durante a realização dessa tarefa, a dependência do conhecimento dos locais da imagem que representariam o estado atual da planta. Para a lâmina de 25%, o desafio ocorreu pela baixa massa foliar da planta a partir do 70° dia do experimento. O maior valor de erro para a lâmina de 50% pode se justificar pela possibilidade de enquadrar as imagens em outras duas lâminas (de 25% e 100%), se o local para coleta da informação da temperatura não for bem indicado. O alto nível de acerto para a lâmina de 100% pode ser justificado pela alta massa foliar desenvolvida pelas plantas sob este regime de irrigação, facilitando a análise da imagem durante todo o ciclo. No geral, pode-se observar que 32% das imagens não foram rotuladas corretamente.

Blaya-Ros et al. (2020) realizou estudo similar para avaliar o estado da água em cerejeiras jovens submetidas a diferentes níveis de estresse hídrico. O autor utilizou imagens térmicas obtidas por dispositivo de baixo custo para estimativa o índice CWSI. O valor do potencial hídrico do caule foi utilizado como um indicador sensível do estresse hídrico na planta, e foi utilizado como comparativo dos valores obtidos pelo uso das imagens termais. Os autores constataram forte relação entre o índice CWSI com o potencial hídrico do caule. Concluindo que o uso de imagens térmicas obtidas a partir de dispositivos de baixo custo forneceu dados confiáveis que foram usados para estimar o estado da água na planta na cultura da cerejeira.

5.1.2 Avaliação pelo modelo

Para a avaliação realizada pelo modelo, foram consideradas duas taxas de acerto, a primeira sendo a taxa de acurácia alcançada pela rede durante o seu treinamento e a segunda, a taxa de acurácia da rede quando avaliando os 30% de imagens que não foram apresentadas à rede durante seu treinamento.

Como pode ser observado no Gráfico 3, a rede inicia com acurácia de aproximadamente 70%, fato este que pode ser justificado por seu treinamento prévio. Conforme o seu treinamento progride e a rede é ajustada, pode-se observar o crescimento da acurácia atingindo o valor de 91% após 240 mil passos.

Quando aplicada no grupo de imagens separadas para a validação do treinamento, a rede obteve acurácia de 82%. Esse valor de acurácia corrobora o valor alcançado pela rede durante seu treinamento e demonstra que, após o novo treinamento, a rede foi capaz de reconhecer as classes de interesse para o domínio deste trabalho. Outro fato a se destacar é que durante esta fase foram avaliadas mais de 1.000 imagens em menos de um minuto.

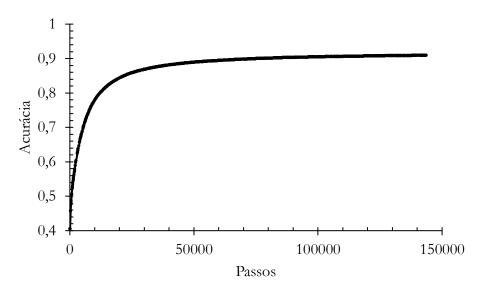


Gráfico 3. Acurácia atingida durante treinamento do modelo

Nota: Época representa o número de vezes que o modelo avaliou todos os exemplos usados para o treinamento.

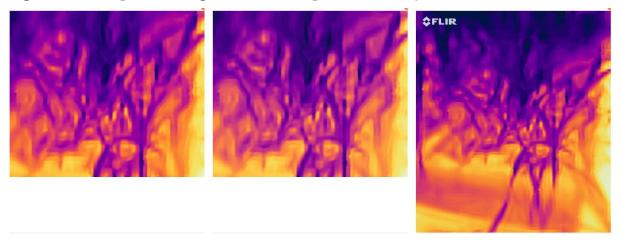
Fonte: Elaborado pelo autor.

Diversos autores utilizaram abordagens de redes neurais profundas com sucesso para prever o estresse hídrico da cultura, obtendo índices de correlação (R²) entre indicadores fisiológicos reais e estimados de 0,65 e 0,93 (KING e SHELLIE, 2016; SALVADOR GUTIÉRREZ et al. 2018.; ROMERO et al. 2018). Abordagens de aprendizado profundo de máquina alcançaram desempenho favorável na classificação do status da água em plantas com acurácia de 83,11% a 98,84% (AN et al., 2019; JIANG et al., 2019; GIMÉNEZ-GALLEGO et al., 2020; ZHUANG et al., 2017; 2020). KUMAR et al. (2020) desenvolveu dois modelos de redes neurais profundas para prever o índice CWSI usando dados de temperatura do ar, umidade relativa e temperatura do dossel obtidas em imagens termais. De acordo com Zhou et al. (2021), a implementação dos modelos de redes neurais profundas demonstrou ser uma ferramenta mais rápida e confiável não só para revelar a relação entre CWSI e indicadores fisiológicos da planta, mas também na determinação do estresse hídrico da cultura para apoiar o planejamento da irrigação.

Entre as vantagens na utilização da rede *Inception-ResNet-v2*, podem se destacar algumas transformações realizadas nas imagens utilizadas pela rede, como a distorção das imagens, tendo como objetivo a criação de ruídos e variabilidades de exemplo para seu treinamento. Assim, a rede será capaz de melhor generalizar, pois possibilitará distinguir em uma imagem o que deve ser

analisado. A Figura 24 apresenta algumas distorções realizadas nos exemplos durante o treinamento.

Figura 24. Exemplos de imagens distorcidas para cana-de-açúcar durante o treinamento



Fonte: Imagens capturadas pelo autor com FlirOne®.

5.1.3 Comparação das avaliações

Realizou-se a comparação do desempenho entre os dois métodos para as avaliações das 30% imagens que foram separadas para esta tarefa, com o objetivo de determinar qual dos métodos demonstrou maior eficiência na classificação das imagens utilizadas. A comparação entre ambos foi realizada utilizando os critérios referentes à matriz de confusão (sensibilidade, precisão e acurácia), ao gráfico ROC e à UAC. A Tabela 8 apresenta a matriz de confusão para as avaliações feitas pelo especialista. A Tabela 9 apresenta a matriz de confusão gerada para a avaliação realizada pela rede neural.

Tabela 8. Matriz de confusão para a avaliação por especialista

		Predita							
		25% CAD	50% CAD	100% CAD	Sensibili dade	Precisão	Acurácia	NFP	
	L25%	204	80	33	0,772	0,643	0,646	0,281	
Atual	L50%	38	187	114	0,556	0,551	-	0,168	
•	L100%	22	69	259	0,638	0,740	-	0,078	

Atual refere-se à classe conhecida da amostra, predita refere-se à classe associada pela rede neural à amostra, 25%, 50%, 100% da CAD as classes associadas aos níveis de irrigação, acurácia o número de amostras classificadas corretamente. Precisão é o número de predições corretas para uma classe entre todas as predições, e Recall se refere ao número de classificações feitas corretamente e número de falso positivo (NFP) o número de predições para a classe errônea.

Fonte: Elaborada pelo autor.

Tabela 9. Matriz de confusão para a avaliação pela rede neural

			Predita					
		25% CAD	50% CAD	100% CAD	Sensibili dade	Precisão	Acurácia	NFV
	L25%	292	23	18	0,811	0,876	0,832	0,073
Atual	L50%	57	243	33	0,829	0,729	-	0,190
-	L100%	11	27	305	0,889	0,889	-	0,034

Fonte: Elaborada pelo autor.

A avaliação das imagens utilizando a rede neural convolucional após a aplicação do treinamento demonstrou acurácia 19% superior quando comparada à avaliação pelo especialista (Tabelas 8 e 9). Outro fato a ser considerado são os melhores valores de precisão para o modelo, sendo este superior à classificação manual em 23% para a classe de 25, 17% para a classe de 50 e 14% para a classe de 100. Quando analisadas as taxas de sensibilidade, a rede neural foi melhor em 4% na classe de L25%, 27% para a de L50% e 25% para a L100%, demonstrando sua melhor capacidade de separação entre as classes. Outro fator que confirma a superioridade do método utilizando rede neural são os valores de f-score (Tabela 10) alcançados pelo modelo, sendo superior em 14% para a classe de 25, em 22% para a classe de 50 e 19% para a classe de 100, demonstrando assim um melhor equilíbrio entre sensibilidade e precisão.

Jiménez-Bello et al. (2011) desenvolveu um processo automático para estimativa do estado da água em plantas de citros utilizando 44 imagens térmicas. Foi estimado pelas imagens térmicas de forma manual por especialista e por regressão linear utilizando o modelo de regressão "REG", disponível no software estatístico SAS, a temperatura do dossel e o potencial hídrico das plantas. Os resultados obtidos demostraram desempenho superior ($R^2 = 0,81$) para as estimativas utilizando o método automático por regressão em relação ao método por especialista ($R^2 = 0,78$). Esses resultados corroboram com os obtidos neste trabalho.

Petrie et al. (2019) realizaram estudo para avaliar o estado hídrico na cultura da uva irrigadas sob diferentes regimes hídricos, utilizando câmera termal de baixo custo acoplada em smartphone. Foi utilizado o software Minitab 18 para análise dos dados das imagens, através de análise de regressão para estimar a temperatura da copa e das folhas para cálculo do índice CWSI e do índice de condutância estomática. Os autores concluíram que o melhor desempenho de predição obtido foi para o índice CWSI por este não requer entrada de dados meteorológicos. Foi obtido índice de correlação R² de 0,61 entre o índice de condutância estomática e o potencial hídrico do caule medido, e 0,74 com o CWSI. Os autores concluíram ainda que o uso de câmeras

térmicas de baixo custo acopladas em smartphones têm o potencial de ser uma ferramenta fácil e acessível para a avaliação do estado da água na planta, e para tomar melhores decisões de irrigação.

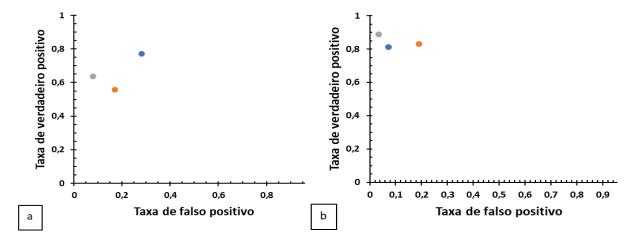
Tabela 10. F-score manual e do modelo neural com transfer learning

	F-score Manual	F-score Modelo Neural
L25%	0,702	0,842
L50%	0,554	0,776
L100%	0,685	0,889

Fonte: Elaborada pelo autor.

Para a análise ROC de ambos os métodos, foram calculados os pontos para cada uma das classes usando a estratégia um contra todos e representados graficamente como apresentado no Gráfico 4.

Gráfico 4. (a) Gráfico ROC para a análise manual, (b) Gráfico ROC para a rede com transfer learning



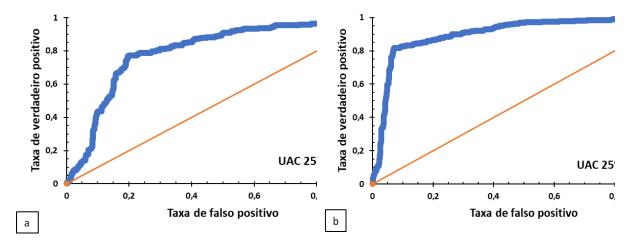
Fonte: Elaborados pelo autor. (cinza corresponde a lâminas de 100% da CAD, laranja, 50% CAD e azul 25% da CAD)

Como definido pela análise ROC, modelos próximos ao ponto (0,1) demonstram melhor qualidade nas avaliações para o problema analisado. Nota-se que a rede neural treinada com a técnica de *transfer learning* obteve valores mais próximos a este ponto para todas as classes, confirmando assim o melhor desempenho da rede em comparação com o método manual.

Por fim, para uma melhor compreensão dos resultados obtidos, foram geradas simulações das curvas ROC para cada um dos treinamentos, bem como calculada a área sob a curva (AUC). Como a classificação realizada possui três classes e o número de curvas cresce exponencialmente com o número de classes (PRATI et al., 2008), adotou-se a estratégia um contra todos durante a

análise para mensurar a capacidade de separação de cada uma das classes avaliadas em ambos os métodos.

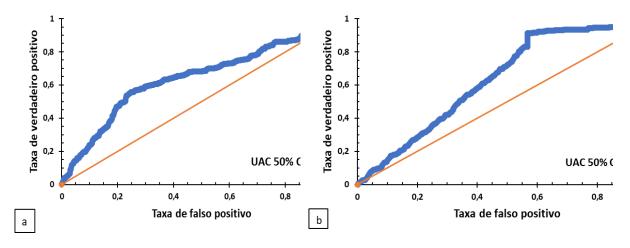
Gráfico 5. Simulação de sensibilidade usando curva ROC para a classe L25%(a) manual, (b) rede com *transfer learning*



Fonte: Elaborados pelo autor.

Sendo a UAC a representação da capacidade de separação do modelo da classe de interesse, pode-se notar que, para a classe de 25% da lâmina para atingir a CAD (Gráfico 5), o método utilizando a rede neural foi 10% superior ao método manual. Para a classe correspondente a L50%, ambos os métodos demonstraram capacidade de separação aproximada, sendo o modelo neural superior em apenas 1% (Gráfico 6). Isso se justifica pelo fato de que as imagens pertencentes à classe de L50% podem ser classificadas erroneamente como pertencentes à classe de 25 ou 100%.

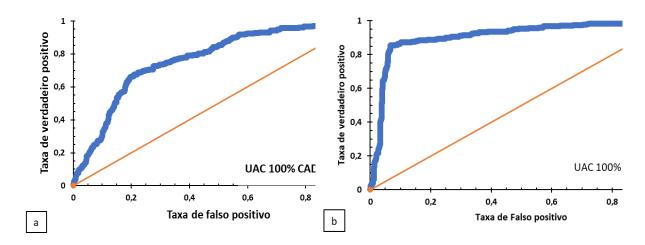
Gráfico 6. Simulação de sensibilidade usando curva ROC para a classe de 50% da CAD (a) manual, (b) rede com *transfer learning*



Fonte: Elaborados pelo autor.

Para a classe de 100% (Gráfico 7), o modelo neural foi superior ao método manual em 14%. Nota-se, pelas simulações, que o método utilizando modelo neural produz uma maior área sob a curva, confirmando sua melhor capacidade de separação das classes de interesse.

Gráfico 7. Simulação de sensibilidade usando curva ROC para a classe L100% (a) manual, (b) rede com *transfer learning*



Fonte: Elaborados pelo autor.

5.2 Cultura da soja

5.2.1 Avaliação pelo modelo

Para o treinamento conduzido com a cultura da soja, o modelo foi capaz de alcançar a taxa de acurácia de 87,9 % (Gráfico 7). Porém, como descrito anteriormente para sistemas de classificação, apenas a análise da acurácia não é o suficiente para avaliar sua capacidade de realizar uma tarefa; assim, a análise ROC com o treinamento da soja também foi realizada com o intuito de avaliar a capacidade separadora do modelo para o treinamento com esta cultura (Gráfico 9).

Acurácia Passos

Gráfico 8. Acurácia atingida durante treinamento do modelo

Fonte: Elaborado pelo autor.

Como pode ser observado no gráfico, apesar da alta acurácia alcançada pelo modelo durante o seu treinamento, o modelo apresenta ser capaz de separar apenas duas classes das demais. A capacidade separadora inferior ao treinamento conduzido com a cana-de-açúcar pode ser justificada pela baixa quantidade de exemplos (1.181), sendo que 30% destes foram separados para teste, ocasionando pouca capacidade de generalização da rede neural. Para a lâmina de 130% da fração para atingir a CAD, o comportamento já é esperado, pois, como descrito anteriormente, plantas sob regime pleno de água apresentam no máximo uma temperatura 4°C inferior à temperatura ambiente, independente do superávit hídrico; já a lâmina de 70% advém da baixa quantidade de exemplos para o treinamento.

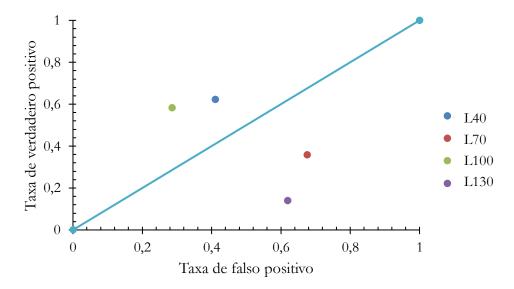


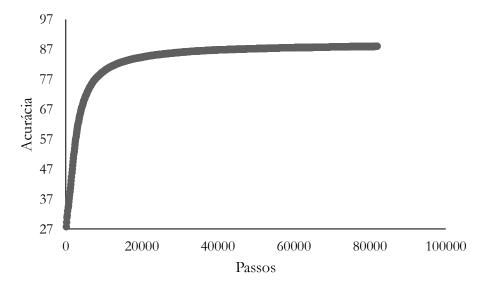
Gráfico 9. Gráfico ROC obtido após treinamento do modelo

Fonte: Elaborado pelo autor.

5.3 Treinamento simultâneo com cana-de-açúcar e soja

Como descrito anteriormente, a rede foi treinada para avaliar sua capacidade de realizar a predição de déficit hídrico em mais de uma cultura. O valor de acurácia durante o treinamento conjunto está apresentado no Gráfico 10. Como pode ser observado durante o treinamento, a rede foi capaz de atingir a acurácia de 88,7%; 2% inferior ao treinamento realizado apenas com a canade-açúcar e 1% superior ao treinamento apenas com soja

Gráfico 10. Acurácia atingida pelo modelo referente ao treinamento conjunto da cana-deaçúcar e soja



Fonte: Elaborado pelo autor.

Para a capacidade separadora do modelo, pode-se notar que o modelo foi capaz de melhor identificar as classes de interesse, demonstrando inclusive ser capaz de distinguir a classe de L70% para a soja, classe esta que o modelo não demonstrava ser capaz de separar quando treinado apenas com os exemplos da soja. O gráfico ROC para o treinamento conjunto está apresentado a seguir.

1 Taxa de verdadeiro positivo 0,8 L40 0,6 L70 L100 0,4 L130 L25 0,2 L50 L100 0,2 0,4 0,6 0,8 1 Taxa de falso positivo

Gráfico 11. Gráfico ROC obtido após o treinamento conjunto com soja e cana-de-açúcar

Fonte: Elaborado pelo autor.

Como demonstrado anteriormente, a classe de 130% da lâmina para atingir a CAD do solo já era prevista como não separável. O incremento na capacidade separadora apresentado no treinamento conjunto pode ser justificado pelo maior número de exemplos utilizados durante o treinamento – em torno de 6 mil exemplos –, possibilitando assim à rede uma maior capacidade de generalização durante seu treinamento. Outro fato a ser observado é que o método proposto foi capaz de realizar a avaliação para mais de uma cultura, fato este indicado pelo fato de os pontos ROC estarem no quadrante superior esquerdo do gráfico ROC.

6 CONCLUSÕES

A utilização de uma rede convolucional previamente treinada com a técnica de *transfer* learning, demostrou-se válida para análise de imagens térmicas, sendo capaz de reconhecer classes de estresse hídrico, bem como demostrou acurácia superior a análise manual . Sendo capaz de reduzir o tempo necessário para a avaliação da mesma quantidade de imagens de dias para minutos, relevando um fator positivo para estudos futuros com as técnicas utilizadas.

As imagens térmicas capturadas com câmeras de baixo custo, como a utilizada neste trabalho, demostrou-se ser útil para a análise realizada, fato este que pode ser justificado pela maneira como a imagem é analisada, pixel a pixel.

Como proposta de trabalhos futuros, pode-se comparar os resultados aqui obtidos, com a disponibilidade hídrica quando calculada por meio de parâmetros climáticos a fim de determinar a aderência das avaliações. É possível investigar a utilização dos valores providos pelo avaliador manual das imagens, para o treinamento de um novo modelo que seja capaz de realizar a regressão a partir de imagens, e determinar o valor do CWSI da imagem ao invés de classificar a imagem, auxiliando assim na obtenção de valores que abranjam toda a faixa do índice (O a 1) e não apenas as classes que foram utilizadas no experimento, o que possibilita maior versatilidade na verificações do estresse hídricos das plantas.

Há possibilidade de avaliar outras topologias de redes neurais como por exemplo implementações que utilizem a segmentação das imagens, contribuindo com a validação da proposta deste trabalho.

Considerando as condições em que o presente estudo foi desenvolvido, e com base nos resultados obtidos, foi possível chegar às seguintes conclusões:

- a) Redes neurais convolucionais demonstram aplicabilidade para a predição de estresse hídrico a partir de imagens termais e a técnica de transfer learning auxilia no processo de treinamento do modelo Inception-reNet-v2.
- b) A substituição da avaliação do estresse hídrico pela utilização de redes neurais treinadas para esse propósito demonstrou-se viável, tendo a proposta aqui apresentada um grau de acerto superior à avaliação manual na classificação do nível de estresse hídrico das mesmas plantas, demonstrando ser uma ferramenta de auxílio ao pequeno e médio produtor rural.
- C) O CWSI associado a redes neurais convolucionais demonstrou-se aplicabilidade para inferência do nível de estresse hídrico da planta, pode-se destacar também que além disso essa metodologia requer poucos insumos suplementares, pode ser um método barato para fornecer feedback na pesquisa agrícola bem como para os produtores e usado como uma ferramenta para a previsão da variação espacial na produção ao longo de uma estação de cultivo.

REFERÊNCIAS

ALEMI, Alex. Improving Inception and Image Classification in TensorFlow. In: *Google AI Blog.* Aug. 31, 2016. Disponível em: https://ai.googleblog.com/2016/08/improving-inception-and-image.html. Acesso em: 04 jam. 2018.

AMARI, S. Natural Gradient Works Efficiently in Learning. *Neural Computation*, v. 10, n. 2, p. 251–276, fev. 1998. Disponível em: http://www.mitpressjournals.org/doi/10.1162/089976698300017746. Acesso em: : 20 Jul. 2018.

AN, J., LI, W., LI, M., CUI, S., YUE, H. Identification and classification of maize drought stress using deep convolutional neural network. Symmetry 11 (2), 1–14 2019.

APOLO-APOLO, O.E.; MARTÍNEZ-GUANTER, J.; PÉREZ-RUIZ, M.; EGEA, G. Design and assessment of new artificial reference surfaces for real time monitoring of crop water stress index in maize. Agricultural Water Management. v.240. 2020. Doi. https://doi.org/10.1016/j.agwat.2020.106304.

ARONOFF, S. Classification Accuracy - A User Approach, Photogram. *Engin. and Remote Sensing,* v. 48, n. 8, p. 1299-1307, 1982.

ATLAS, L. E., HOMA, T.; MARKS II, R. J. An Artificial Neural Network for Spatio-Temporal Bipolar Patterns: Application to Phoneme Classification. In: ANDERSON, D. Z. (Ed.). *Neural Information Processing Systems*. [s.l.] American Institute of Physics, 1988. p. 31–40.

AZEVEDO, R. A.; CARVALHO, R.F; CIA, M.C.; GRATÃO P. L. Sugarcane Under Pressure: An Overview of Biochemical and Physiological Studies of Abiotic Stress. *Tropical Plant Biology*, v. 4, n. 1, p. 42–51, 28 mar. 2011

BLAYA-ROS. P.J.; BLANCO.V.; DOMINGO. R.; SOTO-VALLES. F.; TORRES-SÁNCHEZ. R.; Feasibility of Low-Cost Thermal Imaging for Monitoring Water Stress in Young and Mature Sweet Cherry Tress. *Applied Sciences*. MDPI. V.10. p.2-17.2020

BEHNKE, S. Hierarchical Neural Networks for Image Interpretation. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003. v. 2766

BLONQUIST, J. M.; NORMAN, J. M.; BUGBEE, B. Automated measurement of canopy stomatal conductance based on infrared temperature. *Agricultural and Forest Meteorology*, v. 149, n. 12, p. 2183–2197, 2009.

BRADLEY, A. P. The use of the area under the ROC curve in the evaluation of machine learning algorithms. *Pattern Recognition*, v. 30, n. 7, p. 1145–1159, 1997.

BULANON, D. M.; BURKS, T. F.; ALCHANATIS, V. Image fusion of visible and thermal images for fruit detection. *Biosystems Engineering*, v. 103, n. 1, p. 12–22, May. 2009. Disponível em: https://linkinghub.elsevier.com/retrieve/pii/S1537511009000610. Acesso em: 06 jan. 2019.

CAMARGO, M. B. P., HUBBARD, K. G. Drought sensitivity indices for a sorghum crop. *Journal Prod. Agric.*, v. 12, p. 312-316, 1999.

CAMPBELL, G.S.; NORMAN, J.M. An introduction to environmental biophysics. New York: Springer-Verlag, 1998. 286 p.

- CANZIANI, A.; PASZKE, A.; CULURCIELLO, E. An Analysis of Deep Neural Network Models for Practical Applications. p. 1-7, 2016. Disponível em: http://arxiv.org/abs/1605.07678. Acesso em: 27 jul. 2019.
- CAPUTO, M. M.; BEAUCLAIR, E. G. F.; SILVA, M. A.; PIEDADE, S. M. F. Resposta de genótipos de cana-de-açúcar à aplicação de indutores de maturação. *Bragantia*, v. 67, n. 1, p. 15–23, 2008.
- CASBEER, D. W.; BEARD, R.W.; MCLAIN, T. Forest fire monitoring with multiple small UAVs. In: AMERICAN CONTROL CONFERENCE, 2005. Proceedings IEEE, 2005. Disponível em: http://ieeexplore.ieee.org/document/1470520/. Acesso em: 18 jun. 2017.
- CHACON, M., MANICKAVASAGAN, A., FLORES-TAPIA, D., THOMAS, G.; JAYAS, D. S. Segmentation of Wheat Grains in Thermal Images Based on Pulse Coupled Neural Networks. IEEE INTERNATIONAL CONFERENCE ON IMAGE PROCESSING ICIP 2007. San Antonio, Texas, United States, 2007. p. II-273-II-276. doi: 10.1109/ICIP.2007.4379145. Disponível em: https://ieeexplore.ieee.org/document/4379145. Acesso em: 07 mai. 2020.
- CHAERLE, L., LEINONEN, I., JONES, H.G., VAN DER STRAETEN, D.. Monitoring and screening plant populations with combined thermal and chlorophyll fluorescence imaging. *J. Exp. Bot.* v. 58, p. 773–784, 2007. Disponível em: https://doi.org/10.1093/jxb/erl257. Acesso em: 05 agos. 2019.
- CIIAGRO. Centro Integrado de Informações Agrometeorológicas. *Índice de estresse hídrico da cultura*. 2009. Disponível em: http://www.ciiagro.sp.gov.br/def_4.html. Acesso em: 29 jan. 2020.
- CIRESAN, D.; MEIER, U.; SCHMIDHUBER, J. Multi-column deep neural networks for image classification. In: IEEE Conference on Computer Vision and Pattern Recognition, 2012. *Proceedings*... IEEE, Jun. 2012. Disponível em: http://ieeexplore.ieee.org/document/6248110/. Acesso em: 13 mar. 2019.
- CONAB. ACOMPANHAMENTO DA SAFRA BRASILEIRA DE CANA-DE-AÇÚCAR. v. 6 Safra 2019/20, n.1 Primeiro levantamento, 17 maio de 2019. Acesso em: 20 jul. 2020.
- CONAB. Companhia Nacional de Abastecimento. 2º Levantamento da Safra de Grãos 2020/2021. Acesso em: https://www.conab.gov.br/ultimas-noticias/3691-producao-de-graos-da-safra-2020-21-segue-como-maior-da-historia-268-9-milhoes-de-toneladas. Acesso em: 20 jan. 2021.
- CONGALTON, R. G. A review of assessing the accuracy of classifications of remotely sensed data. Remote Sensing of Environment, v. 37, Issue 1, p. 35-46, 1991.
- CONGALTON, R.G. A comparison of sampling schemes used in generating error matrices for assessing the accuracy of maps generated from remotely sensed data. *Photogrammetric Engineering and Remote Sensing*. V. 54, p. 593-600, 1988.
- CRAPARO, A. C. W. STEPPE, K.; VAN ASTEN, P. J. A.; LADERACH, P.; JASSOGNE, L. T. P.GRAB, S. W.; Application of thermography for monitoring stomatal conductance of Coffea arabica under different shading systems. *Science of the Total Environment*, v. 609, p. 755-763, 2017.
- DAS, A.; PAUL, R. Opportunities and Challenges in Explainable Artificial Intelligence (XAI): A Survey. 2020. https://arxiv.org/abs/2006.11371.
- DEERY, D. M.; REBETZKE, G, J.; JIMENES-BERNI, J. A.; JAMES, R. A.; CONDON, A. G.; BOVIL, W. D.; HUTCHINSON, P.; SCARROW, J.;DAVE, R.; FURBANK, R. T. Methodology for High-Throughput Field Phenotyping of Canopy Temperature Using Airborne Thermography. *Frontiers in Plant Science*, v. 7, p. 1808, 2016.

- DIAS-MARTINS, A. M. PESSANHA, K. L. F.; PACHECO, S.; RODRIGUES, J. A. S.; CARVALHO, C. W. P. de. Potential use of pearl millet (Pennisetum glaucum (L.) R. Br.) in Brazil: Food security, processing, health benefits and nutritional products. *Food Research International*, v. 109, p. 175-186, Jul. 2018.
- DINARDO-MIRANDA, L. L.; VASCONCELLOS, A. C. M. DE; LANDELL, M. G. DE A. (Eds.). Canade-açúcar. Campinas: Instituto Agronômico, 2008.
- DONAHUE, S. P.;DANIEL, B. A.; NEELYL, D. e; ARNOLD, R. W.; SILBERT, D.; REBEN J. B.; . Guidelines for automated preschool vision screening: A 10-year, evidence-based update. *Journal of American Association for Pediatric Ophthalmology and Strabismus*, v. 17, n. 1, p. 4-8, Feb. 2013.
- DUARTE ,B., SANTOS, D., MARQUES, J.C., CAÇADOR, I. Biophysical probing of Spartina maritima photo-system II changes during prolonged tidal submersion periods. *Plant Physiology and Biochemistry*, v. 77, p. 122-132, Apr. 2014. Disponível em: https://linkinghub.elsevier.com/retrieve/pii/S0981942814000370. Acesso em: 23 sep. 2019.
- DURO, D. C.; FRANKLIN, S. E.; DUBÉ, M. G. A comparison of pixel-based and object-based image analysis with selected machine learning algorithms for the classification of agricultural landscapes using SPOT-5 HRG imagery. *Remote Sensing of Environment*, v. 118, p. 259–272, 2012. Disponível em: http://dx.doi.org/10.1016/j.rse.2011.11.020. Acesso em: 11 nov. 2019.
- EGAN, J. P., Signal detection theory and ROC analysis. New York, USA: Academic Press, 1975.
- ELSAYED, S.;ELHOWEITY, M.; IBRAHIM, H. H.; DEWIR, Y. H.; MIGDADI, H. M.; SCHMIDHALTER, U. Thermal imaging and passive reflectance sensing to estimate the water status and grain yield of wheat under different irrigation regimes. *Agricultural Water Management*, v. 189, p. 98-110, 2017.
- FLACH, P.; WU, S. Repairing concavities in ROC curves. In: INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE (IJCAI'2005), 19. *Proceedings...*Edinburgh (UK), 2005, pp. 702–707.
- GADE, R.; MOESLUND, T.B. Thermal cameras and applications: a survey. Machine Vision and Applications, Berlin, v. 25, n. 1, p. 245–262, 2014.
- GARCIA, A.; BOUHID ANDRE, R. G.; FERREIRA, M. I.; PAÇO, T. de. Comparação de modelos para avaliação do estresse hídrico em cultura de nectarinas. *Revista Brasileira de Agrometeorologia*, Sete Lagoas, v. 8, n. 1, p. 43-48, 2000
- GARCÍA-TEJERO, I. F.; HERNÁNDEZ, A.; PADILHA-DÍAS, C. M.; DIAZ-ESPEJO, A.; FERNÁMDEZ, J. E.. Assessing plant water status in a hedgerow olive orchard from thermography at plant level. *Agricultural Water Management*, v. 188, p. 50-60, Jul. 2017.
- GARCÍA-TEJERO, I. F. et al. Linking canopy temperature and trunk diameter fluctuations with other physiological water status tools for water stress management in citrus orchards. *Functional Plant Biology*, v. 38, n. 2, p. 106-117, 2011.
- GARCÍA-TEJERO, I. F.; ZUAZO, V. H. D.; MURIEL, J. L.; JIMÉNEZ-BOCANEGRA, J. A.. Thermal data to monitor crop-water status in irrigated Mediterranean viticulture. *Agricultural Water Management*, v. 176, p. 80–90, 1 Oct. 2016. Disponível em: https://www.sciencedirect.com/science/article/pii/S0378377416301706. Acesso em: 25 jan. 2019.
- GARCÍA-TEJERO, I. F.; GUTIÉRREZ-GORDILLOS.ORTEGA-ARÉVALOC.IGLESIAS-CONTRERASM.MORENOJ.M.SOUZA-FERREIRAL.DURÁN-ZUAZOV.H. . Thermal imaging to monitor the crop-water status in almonds by using the non-water stress baselines. *Scientia Horticulturae*, v. 238, p. 91-97, ago. 2018.
- GASTWIRTH, J. L. A general definition of the Lorenz curve. *Econometrica*, v. 39, n. 6, p. 1037–39, 1971.

- GAVA, R.; FRIZZONE, J.; SNYDER, R.; JOSÉ, J.; FRAGA E. JR,; PERBONI, A.. Estresse hídrico em diferentes fases da cultura da soja. Revista Brasileira de Agricultura Irrigada, v.9, n.6, p.349-359, 2015. Disponível em: http://www.inovagri.org.br/revista/index.php/rbai/article/view/368. Acesso em: 21 dez. 2019.
- GAVA, R.; FRIZZONE, J. A.; SNYDER, R. L.; ALMEIDA, B. M.; FREITAS, P. S. L.; REZENDE, R. Estratégias de manejo de déficit hídrico na irrigação da cultura da soja. *Brazilian Journal of Biosystems Engineering*, Tupã-SP, v. 10, n. 3, p. 305-315, 2016.
- GIMÉNEZ-GALLEGO, J., GONZ´ ALEZ-TERUEL, J.D., JIM´ENEZ-BUENDÍA, M., TOLEDO-MOREO, A.B., Soto-Valles, F., Torres-Sanchez, ´R., 2020. Segmentation of multiple tree leaves pictures with natural backgrounds using deep learning for image-based agriculture applications. Appl. Sci. (Switzerland) 10 (1). https://doi.org/10.3390/app10010202.
- GINEVAN, M. E. Testing land use accuracy; another look. *Photogrammetric Engineering and Remote Sensing*, v. 45, n. 10, p. 1371-1377, 1979.
- GIRALDO-GONZÁLEZ, M. M.; RODRÍGUEZ, J. P.. Comparison of statistical and machine learning models for pipe failure modeling in water distribution networks. *Water* (Switzerland), v. 12, i. 2, 2020.
- GOOGLE DEVELOPERS. Machine Learning. Crash Course. *Classification*: Precision and Recall, 2020. Disponível em: https://developers.google.com/machine-learning/crash-course/classification/precision-and-recall Acesso em: 14 abr. 2019.
- HANLEY, J. A.; MCNEIL, B.J. The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve. Radiology, v. 143, p. 29-36. 1982. http://dx.doi.org/10.1148/radiology.143.1.7063747
- HAYKIN, S. Redes neurais: princípios e prática. Porto Alegre: Bookman, 2001.
- HEBB, D. O. Organization of behavior. New York: Wiley, 1949.
- HINTON, G. E. Reducing the Dimensionality of Data with Neural Networks. *Science*, v. 313, n. 5786, p. 504-507, 28 jul. 2006. Disponível em: http://www.sciencemag.org/cgi/doi/10.1126/science.1127647. Acesso em: 25 fev. 2019.
- IAFFE, A.; PINTO, H.S.; ZULLO JR, J.; ASSAD, E.D.; OLIVER, A.; CORAL, G. Aplicação da termometria a infravermelho como indicativo da recuperação do potencial hídrico de cafeeiros irrigados e não irrigados durante a floração, em Garça SP. In: SIMPÓSIO DE PESQUISA DOS CAFÉS DO BRASIL, 3., 2003, Porto Seguro. *Anais...* Porto Seguro: SBI Café, 2003. p. 54.
- IDSO, S. B., JACKSON, R. D., PINTER, P. J., REGINATO, R. J.; HATFIELD, J. L. Normalizing the stress-degree-day parameter for environmental variability. *Agricultural Meteorology*, v. 24, p. 45-55, 1981.
- JACKSON, R. D. Canopy temperature and crop water stress. In: HILLEL, D. *Advances in irrigation*. New York: Academic Press, 1982. p. 43-85.
- JACKSON, R.D.; IDSO, S.B.; REGINATOR, R.J.; PINTER, P.J. Canopy temperatureas a crop water stress indicator. WaterResourcesResearch, Washington, v. 17, n.4, p. 1133–1138, 1981.
- JACKSON, R.D.; KUSTAS, W.P.; CHOUDHURY, B.J. A reexamination of the cropwater stress index. Irrigation Science, New York, v. 9, n. 4, p. 309–317, 1988.
- JAMES, G. (ED.). Sugarcane. Second Edi ed. [s.l.] Blackwell Science Ltd, 2004.
- JANSSEN, L. L. F.; VAN DER WEL, F. J. M. Accuracy assessment of satellite derived land cover data: a review. *Photogrammetric Engineering and Remote Sensing*, n. 60, 419-426, 1994.

- JESUS, J. M., DANKO, A. S., FIÚZA, A.; BORGES, M. -T. Phytoremediation of salt-affected soils: a review of processes, applicability, and the impact of climate change. *Environ. Sci. Pollut. Res.* n. 22, v. 9, p. 6511-6525. 2015. doi:10.1007/s11356-015-4205-4.
- JIANG, B., WANG, P., ZHUANG, S., LI, M., GONG, Z., 2019. Drought stress detection in the middle growth stage of maize based on gabor filter and deep learning. Chinese Control Conference, CC
- JIMÉNEZ-BELLO, M.A.; BALLESTER, C.; CASTEL, J.R.; INTRIGLIOLO, D. S. Development and validation of an automatic thermal imaging process for assessing plant water status. Agricultural Water Management. N. 10, v. 98, p. 1497-1504. 2011. https://doi.org/10.1016/j.agwat.2011.05.002. Issn- 0378-3774.
- KINGMA, D.,BA, J.ADAM: A Method for Stochastic Optimization. International Conference on Learning Representations, 2014.
- KING, B.A., SHELLIE, K.C., 2016. Evaluation of neural network modeling to predict non water-stressed leaf temperature in wine grape for calculation of crop water stress index. Agric. Water Manage. 167, 38–52. https://doi.org/10.1016/j. agwat.2015.12.009.
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, v. 60, n. 6, p. 84–90, 24 May 2017. Disponível em: http://dl.acm.org/citation.cfm?doid=3098997.3065386. Acesso em: 22 mai. 2019.
- KUMAR, N., ADELOYE, A.J., SHANKAR, V., RUSTUM, R. Neural computing modelling of the crop water stress index. Agric. Water Manage. V.239, 2020.
- LECUN, Y.,BOTTOU, L; BENGIO, Y; HAFFNER, P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, i. 11, p. 2278-2324, 1998. Disponível em: http://ieeexplore.ieee.org/document/726791/. Acesso em: 15 set. 2019.
- LER Departamento de Engenharia de Biossistemas. Série de dados climatológicos do Campus Luiz de Queiroz Piracicaba, SP. Disponível em: http://www.leb.esalq.usp.br/leb/postocon.html. Acesso em: 20 de maio de 2020.
- LIU, X.; DENG, Z.; YANG, Y. Recent progress in semantic image segmentation. arXiv.19 Sep. 2018. Disponível em: http://arxiv.org/abs/1809.10198. Acesso em: 9 ago. 2018.
- LOPES, H. dos S.; LIMA R. S; LEAL, F. NELSON, A. C. Scenario analysis of Brazilian soybean exports via discrete event simulation applied to soybean transportation: The case of Mato Grosso State. Research in Transportation Business & Management, v. 25, p. 66-75, dez. 2017.
- LUCAS. P. O. Previsão de Séries Temporais de Evapotranspiração de Referência com Redes Neurais Convolucionais Dissertação. Universidade Federal de Minas Gerais-UFMG, Belo Horizonte-MG, 2019. Disponível em: https://repositorio.ufmg.br/bitstream/1843/32870/6/Dissertacao_Patricia_Lucas.pdf. Acessado em: 15 abr. 2019.
- MAGIOTTO, S.R. Estimativa da evapotranspiração de referência pelo uso da termometria ao infravermelho. 1996. 71 p. Dissertação (Mestrado em Agronomia) Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 1996.
- MAITHRIPALA, D. H. A.; JAYASURIYA, S.; MEARS, M. J. Phantom Track Generation Through Cooperative Control of Multiple ECAVs Based on Feasibility Analysis. *Journal of Dynamic Systems, Measurement, and Control*, v. 129, n. 5, p. 708, 2007. Disponível em: http://dynamicsystems.asmedigitalcollection.asme.org/article.aspx?articleid=1412693. Acesso em: 3 nov. 2018.

MANGUS, D.L., SHARDA, A., ZHANG, N.,. Development and evaluation of thermal infrared imaging system for high spatial and temporal resolution crop water stress monitoring of corn within a greenhouse. Comput. Electron. Agric. 121, 149–159, 2016.

MARQUES, P. A. A.; MARQUES, T. A.; FRIZZONE, J. A. Viabilidade econômica sob condições de risco para a irrigação da cana-de-açúcar na região de Piracicaba- SP. *Irriga*, v. 11, n. 1, p. 55-65, 18 jun. 2006. Disponível em: http://irriga.fca.unesp.br/index.php/irriga/article/view/3225. Acesso em: 1 mar. 2019.

MARTÍNEZ-ROMERO, A.; MARTÍNEZ-NAVARRO, A.; PARDO, J. J.MONTAOYA, F.; DOMÍNGEZ, A.. Agricultural Water Management Real farm management depending on the available volume of irrigation water (part II): Analysis of crop parameters and harvest quality. *Agricultural Water Management*, v. 192, p. 58-70, 2017.

MASSERONI, D., ORTUANI, B., CORTI, M., GALLINA, P.M., COCETTA, G., FERRANTE, A., FACCHI, A., Assessing the reliability of thermal and optical imaging techniques for detecting crop water status under different nitrogen levels. Sustainability (Switzerland) v.9, 1–20, 2017.

MATTHEWS, S. G., MILLER, A. L., PLÖTZ, T., AND KYRIAZAKIS, I. Automated tracking to measure behavioural changes in pigs for health and welfare monitoring. *Scientific Reports*, v. 7, n. 1, p. 17582, 2017.

MCCULLOCH, W.S., PITTS, W. A logical calculus of the ideas immanent in nervous activity. Bulletin of Mathematical Biophysics 5, 115–133 (1943). https://doi.org/10.1007/BF02478259

MCQUEEN, R. J.; GARNER, S. R.; NEVILL-MANNING, C. G.; WITTEN, I. H. Applying machine learning to agricultural data. *Computers and Electronics in Agriculture*, v. 12, n. 4, p. 275-293, 1995.

MOLLER, M.; ALCHANATIS, V.; COHEN, Y.; MERON, M.; TSIPRIS, J.; NAOR, A.; OSTROVSKY, V.; SPRINTSIN, M.; COHEN, S. Use of thermal and visible imagery for estimating crop water status of irrigated grapevine. *Journal of Experimental Botany*, Oxford, v. 58, n. 4, p. 827-838, 2007.

MOORE, P. H.; BOTHA, F. C. (Eds.). Sugarcane: Physiology, Biochemistry, and Functional Biology. [s.l.] John Wiley& Sons, Inc., 2014.

MYLNE, K. R., Decision-making from probability forecasts based on forecast value. *Meteorological Applications*, v. 9, p. 307-315, 2002.

O'SHAUGHNESSY, S. A.; EVETT, S. R.; COLAIZZI, P. D.; HJOVELL, T. A. Using radiation thermography and thermometry to evaluate crop water stress in soybean and cotton. *Agricultural Water Management*, v. 98, n. 10, p. 1523-1535, 2011.

OLIVEIRA, J. R. C. P. de; ROMERO, R. A. F. Transfer Learning Based Model for Classification of Cocoa Pods. 2018 International Joint Conference on Neural Networks (IJCNN), p. 1-6, 2018. Disponível em: . Acesso em: 17 jul. 2019.

PEDERI, Y. A.; CHEPORNIUK, H. S. Unmanned Aerial Vehicles and new technological methods of monitoring and crop protection in precision agriculture. In: 2015 IEEE INTERNATIONAL CONFERENCE ACTUAL PROBLEMS OF UNMANNED AERIAL VEHICLES DEVELOPMENTS (APUAVD), *Proceedings...* IEEE, Oct. 2015. Disponível em: http://ieeexplore.ieee.org/document/7346625/. Acesso em: 22 no. 2019.

PETRIE. P.R.; WANG. Y.; LIU. SCARLETT.; LAM. STANLEY.; WHITTY. M. A.; SKEWES. M.A.; The accuracy and utility of a low cost termal camera and smartphone-based system to assess grapevine water status. **Biosystems Engineering**. V.179. p. 126-139, 2019.

PRATI, R. C.; BATISTA, G. E. A. P. A. e MONARD, M. C., Curvas ROC para avaliação de classificadores. IEEE LATIN AMERICA TRANSACTIONS, v. 6, n. 2, p. 215-222. 2008.

- PRATI, R. C.; FLACH, P. ROCCER: an algorithm for rule learning based on ROC analysis. In INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE (IJCAI'2005), 19. *Proceedings.*.. Edinburgh (UK), 2005, p. 823-828.
- REASHMA, S. R. K. J.; PILLAI, A. S. Edaphic factors and crop growth using machine learning A review. INTERNATIONAL CONFERENCE ON INTELLIGENT SUSTAINABLE SYSTEMS (ICISS) 2017, *Proceedings ...* p. 270-274, 2018.
- ROSENBLATT, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. Psychological Review, 65(6), 386–408.
- ROMERO, M., LUO, Y., SU, B., FUENTES, S., 2018. vineyard water status estimation using multispectral imagery from an uav platform and machine learning algorithms for irrigation scheduling management. comput. electron. agric. 147 109–117.
- SALVADOR GUTIÉRREZ, DIAGO, M.P., FERNANDEZ-NOVALES, ´J., TARDAGUILA, J., VINEYARD water status assessment using on-the-go thermal imaging and machine learning. PLOS ONE 13 (2), 1–18. 2018.
- SILVA, A. C., GATTASS, M., CARVALHO, P. C. P., Diagnosis of Solitary Lung Nodule Using Texture and Geometry in Computerized Tomography Images: Preliminary Results. IEEE LATIN AMERICA TRANSACTIONS, v. 2, n. 2, p. 75-80, 2004.
- SOBAYO, R. et al. Integration of convolutional neural network and thermal images into soil moisture estimation. INTERNATIONAL CONFERENCE ON DATA INTELLIGENCE AND SECURITY (ICDIS), 1. *Proceedings* ... 2018, p. 207-210, 2018.
- SPACKMAN, K. A. Signal detection theory: Valuable tools for evaluating inductive learning. In INT WORKSHOP ON MACHINE LEARNING (ICML'1989), 6. *Proceedings* ... Morgan Kaufmann, 1989, p. 160–163.
- STOLL, M.; SCHULTZ, H. R.; BAECKER, G.; BERKELMANN-LOEHNERTZ, B., Early pathogen detection under different water status and assessment of spray application in vineyards through the use of thermal imagery. *Precision Agriculture*, v. 9, n. 6, p. 407-417. 2008. https://doi.org/10.1007/s11119-008-9084-y
- SZEGEDY, C. et al. Inception_v3. arXiv. p. 4278-4284, 2015. Disponível em: http://arxiv.org/abs/1512.00567. Acesso em: 13 ago. 2019.
- SZEGEDY, C. et al. Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning. *arXiv.* 23 Feb. 2016. Disponível em: http://arxiv.org/abs/1602.07261. Acesso em: 6 mar. 2019.
- TAIGMAN, Y. et al. DeepFace: Closing the Gap to Human-Level Performance in Face Verification. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, *Proceedings...* IEEE, Jun. 2014. Disponível em: http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=6909616. Acesso em: 13 nov. 2019.
- TAIZ, L.; ZEIGER, E. Plant Physiology; Artmed. 6. ed.. 888 p. v. 1. 2015.
- TESTI, L.; GOLDHAMER, D. A.; INIESTA, F.; SALINAS, M. Crop water stress indexes a sensitive water stress indicator in pistachio trees. *Irrigation Science*, New York, v. 26, n. 5, p. 395-405, 2008.
- TEIXEIRA, M. B.; SOARES, F. A. L.; MOURA, L. C. DE. Crescimento vegetativo da cana-de -açúcar submetida a lâminas de irrigação e fertirrigação nitrogenada via gotejamento subsuperficial. Revista Brasileira de Agricultura Irrigada, v. 9, n. 2, p. 79–90, 10 mar. 2015.

TOMPSON, L.; JOHNSON, S.; ASHBY, M.; PERKINS, C.; EDWARDS, P. UK open source crime data: accuracy and possibilities for research. *Cartography and Geographic Information Science*, v. 42, n. 2, p. 97-111, 15 Mar. 2015. Disponível em: http://www.tandfonline.com/doi/abs/10.1080/15230406.2014.972456. Acesso em: 15 jul. 2019.

TOSCANO, S.; FERRANTE, A.; TRIBULATO, A.; ROMANO, D.. Leaf physiological and anatomical responses of Lantana and Ligustrum species under different water availability. *Plant Physiology and Biochemistry*, v. 127, p. 380-392, jun. 2018.

TRENTIN, R. Estimativa de um índice de estresse hídrico para a cultura da cana-de-açúcar com base na temperatura foliar. 2010. 61 p. Dissertação (Meteorologia Agrícola) - Universidade Federal de Viçosa, Viçosa-MG, 2010.

USGS United States Geological Survey. The spatial data transfer standard, January 1990.

VAN GENUCHTEN, M. T. A Closed-form Equation for Predicting the Hydraulic Conductivity of Unsaturated Soils. *Soil Science Society of America Journal*, 1980.

VAN VEEN, F.; LEIJNEN, S. **The Neural Network Zoo**. Disponível em: https://www.asimovinstitute.org/neural-network-zoo. 2019. Acesso em: 8 Jan. 2020.

VIÇOSI, K. A.; FERREIRA, A. A. S.; OLIVEIRA, L. A. B.; RPDRIGES, F. Estresse Hídrico Simulado em Genótipos de Feijão, Milho e Soja. *Journal of Neotropical Agriculture*, v.4, n.5, p.36-42, 20 dez. 2017. Disponível em: http://periodicosonline.uems.br/index.php/agrineo/article/view/2194. Acesso em: 28 mai. 2019.

WAHARTE, S.; TRIGONI, N. Supporting Search and Rescue Operations with UAVs. In: 2010 International Conference on Emerging Security Technologies, Anais...IEEE, set. 2010. Disponível em: http://ieeexplore.ieee.org/document/5600072/>.

WANG, L.; QIU, G.Y.; ZHANG, X.; CHEN, S. Application of a new method to evaluate crop water stress index. *Irrigation Science*, New York, v. 24, n. 1, p. 49-54, 2005.

WIDROW B.; HOFF M. E. Adaptive Switching Circuits. 1960 IRE WESCON Convention Record, 1960, p. 96-104.

Widrow, B. Pattern Recognition and Adaptive Control. IRE-AIEE JOINT AUTOMATIC CONTROL CONFERENCE, *Proceedings* ... p.19-26, August 1962.

WU, A.; SONG, Y.; OOSTEROM, E. J. V; HAMMER, J. L. Connecting Biochemical Photosynthesis Models with Crop Models to Support Crop Improvement. *Frontiers in Plant Science*, v. 7, p. 1518, out. 2016.

YU, M.-H.; DING, G.; GAO, G.; ZHAO, Y. Using Plant Temperature to Evaluate the Response of Stomatal Conductance to Soil Moisture Deficit. *Forests*, v. 6, n. 10, p. 3748-3762, Oct. 2015.

ZEILER, M. D.; FERGUS, R. Visualizing and Understanding Convolutional Networks. In: D. Fleet et al. (Eds.): ECCV 2014, Part I, LNCS 8689, p. 818-833. Springer International Publishing Switzerland 2014

ZHAO, P., JACKSON, P.A., BASNAYAKE, J., LIU, J., CHEN, X., ZHAO, J., ZHAO, X., BAI, Y., YANG, L., ZAN, F., YANG, K., XIA, H., QIN, W., ZHAO, L., YAO, L., LAKSHMANAN, P., FAN, Y.. Genetic variation in sugarcane for leaf functional traits and relationships with cane yield in environments with varying water stress. F. Crop. Res. v. 213, p. 143-153, 2017. https://doi.org/10.1016/j.fcr.2017.08.004

ZHOU, X. H., MCCLISH, D. K.; OBUCHOWSKI, N. A. Statistical Methods in Diagnostic Medicine. John Wiley & Sons Inc, 2002.

ZHOU. Z.; MAJEED. Y.; NARANJO. G.D.; GAMBACORTA. E.M.T. Assessment for crop water stress with infrared thermal imagery in precision agriculture: A review and future prospects for deep learning applicatins. Computers and Electronics in Agriculture. V.182, 2021.

ZHUANG, S., WANG, P., JIANG, B., LI, M., Learned features of leaf phenotype to monitor maize water status in the fields. Comput. Electron. Agric. 172, 2020.

ZHUANG, S., WANG, P., JIANG, B., LI, M., GONG, Z., Early detection of water stress in maize based on digital images. Comput. Electron. Agric. 140, 461–468, 2017.